UNIVERSITÀ POLITECNICA DELLE MARCHE

DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

Insegnamento di New Generation Databases



Anomaly detection su dati biometrici

Relazione di progetto

DOCENTE

Prof.ssa Claudia Diamantini

CANDIDATI

Andrea Altieri

Andrea Flaiani

Anno accademico 2026/2027

Indice

1 Introduzione e dominio applicativo **1**

1.1 Contesto clinico e problematiche dei dati intraoperatori . . . 1
1.2 Scelta del dataset VitalDB e coorte sperimentale. . . . 2
1.3 Impostazione architetturale e struttura dell'elaborato . . . 3

2 Architettura della pipeline dati **5**

2.1 Il modello medallion a tre livelli . . . 5
2.2 Livello bronze: acquisizione e storicizzazione dei dati grezzi. . . . 5
2.3 Livello silver: bonifica fisiologica, imputazione e partizionamento . . . 6
2.4 Evoluzione del modello dati da tabella Parquet a documento BSON . . . 9

3 Archiviazione e governance con MongoDB Time Series **12**

3.1 Archiviazione temporale nel livello gold . . . 12
3.2 Analisi sperimentale di spazio su disco, latenza e valori mancanti . . . 13
3.3 Architettura di data governance e gestione transazionale . . . 14
3.3.1 Catalogo dei casi, contratti di schema e metadati delle tracce . . . 14
3.3.2 Protocollo di caricamento a due fasi e recupero automatico . . . 16
3.4 Pipeline di aggregazione e ottimizzazione delle interrogazioni . . . 17

4 Modelli di anomaly detection **19**

4.1 Impostazione dell'approccio ibrido. . . . 19
4.2 Estrazione dal livello gold e formulazione delle regole cliniche. . . . 19
4.3 Ingegnerizzazione delle feature temporali e imputazione locale . . . 21
4.4 Modelli non supervisionati: isolation forest e autoencoder LSTM . . . 22
4.4.1 Partizionamento casuale nello spazio a otto dimensioni con isolation forest. . . . 22
4.4.2 Architettura ricorrente dell'autoencoder LSTM e gestione della memoria . . . 22
4.5 Valutazione sperimentale sui 500 casi e persistenza degli allarmi . . . 25

5 Ingegnerizzazione del sistema, interfaccia grafica e conclusioni **28**

5.1 Servizi REST con FastAPI . . . 28
5.2 Dashboard web per l'esplorazione clinica e architetturale . . . 29
5.2.1 Vista di telemetria clinica e analisi del consenso . . . 30
5.2.2 Vista di monitoraggio dell'architettura e dei benchmark. . . . 30
5.3 Containerizzazione Docker, orchestrazione e test automatici . . . 31
5.4 Conclusioni, analisi dei limiti e sviluppi futuri . . . 33

Capitolo 1

Introduzione e dominio applicativo

1.1 Contesto clinico e problematiche dei dati intraoperatori

Durante un intervento chirurgico i monitor multiparametrici di sala operatoria acquisiscono in modo continuo i parametri vitali del paziente, tra cui la frequenza cardiaca, la saturazione periferica dell'ossigeno e la pressione arteriosa. Queste serie temporali rappresentano uno strumento essenziale per intercettare precocemente episodi di instabilità emodinamica, ma la loro gestione informatica e l'analisi automatica su larga scala pongono diverse difficoltà strutturali. In primo luogo, le registrazioni reali sono costantemente esposte a **rumore e artefatti strumentali**: il movimento del paziente sul letto operatorio, le interferenze elettromagnetiche generate dal bisturi elettrico o il distacco temporaneo di un sensore producono picchi fisiologicamente impossibili, come frequenze cardiache superiori a 250 bpm o letture pressorie nulle, oltre a frequenti interruzioni del segnale.

A questa rumorosità si affianca l'**asimmetria fisiologica e strutturale delle frequenze di campionamento** tra i diversi canali di monitoraggio. I sensori ottici (come il fotopletismografo a luce rossa e infrarossa per la saturazione d'ossigeno SpO_2) e i conduttori elettrocardiografici per la frequenza cardiaca (HR) sono dispositivi non invasivi passivi che intercettano l'attività cardiopolmonare battito per battito, consentendo al monitor di estrarre un campione numerico continuo ogni secondo (1 Hz) senza interruzioni e senza arrecare alcun disagio al paziente.

Al contrario, la pressione arteriosa non invasiva (**NIBP**) viene rilevata mediante un manicotto pneumatico oscillometrico posizionato attorno al braccio del paziente. Il monitor avvia il gonfiaggio della camera d'aria fino a superare la pressione sistolica per occludere temporaneamente l'arteria brachiale, per poi eseguire un graduale sgonfiaggio misurando le micro-oscillazioni pressorie trasmesse dalla parete vascolare. Questo ciclo fisico richiede dai 30 ai 40 secondi di elaborazione e **non può in alcun modo essere continuativo**: mantenere il bracciale costantemente compresso attorno all'arto bloccherebbe la perfusione sanguigna distale, provocando ischemia acuta dei tessuti, stasi venosa e gravi lesioni neuropatiche da compressione a carico del nervo mediano e ulnare. Per tale ragione, durante un intervento chirurgico il bracciale viene attivato in modo intermittente (tipicamente ogni 2, 3 o 5 minuti), rimanendo completamente sgonfio e inerte per la quasi totalità del tempo.

Quando questi flussi eterogenei devono essere allineati su un'unica linea temporale con passo discreto di un secondo per correlare i parametri vitali e alimentare gli algoritmi di calcolo, la disparità di campionamento si traduce in una marcata **sparsità strutturale** della matrice dati: tra una rilevazione pressoria e la successiva si aprono intervalli vuoti di 80, 120 o più secondi in cui le tre colonne della pressione (`NIBP_SBP`, `NIBP_DBP` e `NIBP_MBP`) risultano prive di misura e valorizzate a `NaN` (valore non disponibile). Come mostrato più avanti, sull'intera coorte sperimentale questa dinamica fisiologica fa sì che oltre il 66% delle celle numeriche grezze sia inizialmente vuoto, imponendo strategie dedicate di conservazione nel livello bronze e di imputazione temporale controllata nel livello silver.

Infine, nei contesti ospedalieri reali si riscontra la quasi totale **assenza di etichette cliniche**

puntuali: raramente un medico annota manualmente ogni singolo secondo di un intervento distinguendo le fasi di normalità fisiologica dagli eventi avversi, rendendo impraticabile l'addestramento diretto di modelli diagnostici puramente supervisionati.

L'obiettivo di questo lavoro è la progettazione e lo sviluppo di una piattaforma completa in grado di governare l'intero ciclo di vita dei tracciati biometrici intraoperatori: dall'acquisizione dei file grezzi alla bonifica degli artefatti, dall'archiviazione ottimizzata su un database temporale non relazionale fino al rilevamento automatico delle anomalie e alla consultazione interattiva tramite interfaccia web.

1.2 Scelta del dataset VitalDB e coorte sperimentale

Per costruire e validare la piattaforma su tracciati clinici reali è stato adottato **VitalDB**, una banca dati pubblica raccolta presso il dipartimento di anestesiologia del Seoul National University Hospital che raccoglie le registrazioni multiparametriche ad alta risoluzione di oltre 6.300 interventi chirurgici. Nelle fasi preliminari dello studio era stato preso in considerazione anche il database MIMIC-IV, ampiamente diffuso nella letteratura scientifica per la terapia intensiva; tuttavia, l'accesso ai dati su PhysioNet richiede una procedura formale di accreditamento con tempi di approvazione incompatibili con un flusso di sviluppo rapido e riproducibile. VitalDB mette invece a disposizione un'interfaccia HTTP pubblica e la libreria ufficiale `vitaldb` per Python, consentendo di automatizzare via codice lo scaricamento dei casi clinici senza vincoli burocratici.

All'interno di VitalDB sono presenti sia le forme d'onda continue ad alta frequenza, come il tracciato elettrocardiografico e pletismografico campionati tra 100 e 500 Hz, sia le serie numeriche già estratte dal monitor multiparametrico alla frequenza di 1 Hz. Nel progetto si è scelto di operare esclusivamente sulle serie numeriche a 1 Hz registrate dal monitor `Solar8000` poiché l'obiettivo centrale del lavoro risiede nell'architettura della base di dati, nella modellazione documentale e nella qualità del dato: l'elaborazione delle forme d'onda grezze avrebbe spostato il baricentro verso algoritmi di filtraggio in frequenza ed estrazione dei picchi, senza apportare benefici significativi alla gestione dei dati temporali.

Nello specifico, l'analisi prende in esame cinque parametri vitali complementari: la frequenza cardiaca `Solar8000/HR` espressa in battiti al minuto (bpm) e la saturazione periferica dell'ossigeno `Solar8000/PLETH_SPO2` espressa in percentuale (%), entrambe acquisite in continuo a 1 Hz, affiancate dalle tre componenti della pressione arteriosa non invasiva misurate in millimetri di mercurio (mmHg) ad intervalli intermittenti di 2–5 minuti, ovvero la pressione sistolica `Solar8000/NIBP_SBP`, la pressione diastolica `Solar8000/NIBP_DBP` e la pressione media `Solar8000/NIBP_MBP`. Dal punto di vista fisiologico, la pressione arteriosa media, approssimabile tramite la relazione $MBP \approx DBP + \frac{1}{3}(SBP - DBP)$, costituisce l'indicatore principale con cui l'anestesista valuta la perfusione degli organi vitali, considerando la soglia di $MBP < 65$ mmHg come limite critico al di sotto del quale cresce il rischio di sofferenza ischemica renale, cardiaca e cerebrale.

Accanto alle cinque tracce biometriche, il sistema acquisisce i metadati anagrafici e ospedalieri dei pazienti, salvati nel file `clinical_data.parquet` con informazioni quali l'età, il sesso e il reparto chirurgico `department`, insieme ai referti delle analisi ematochimiche perioperatorie archiviati in `lab_data.parquet`. La coorte sperimentale su cui è stata validata e misurata l'intera architettura comprende **500 interventi chirurgici completi**, che corrispondono a **5.565.384 secondi grezzi** estratti dalla sorgente e a **5.402.386 secondi attivi** dopo la bonifica, per un volume complessivo superiore a 1.500 ore di monitoraggio reale in sala operatoria.

La dinamica dell'asimmetria di campionamento e l'origine fisiologica della sparsità sono schematizzate visivamente nella Figura 1.1, che mette a confronto sincronizzato le due corsie temporali nei primi due minuti (120 s) di rilevazione.

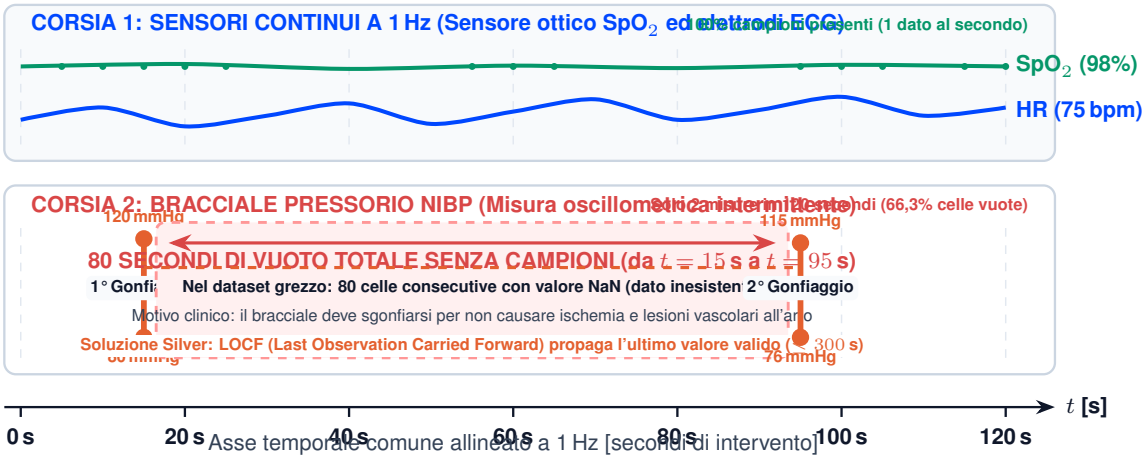


Figura 1.1: Confronto sincronizzato tra il monitoraggio continuo a 1 Hz (SpO_2 ed HR) e la misura intermittente oscillometrica del bracciale (NIBP): evidenza dell'intervallo di 80 secondi di inattività del bracciale tra due gonfiaggi, della conseguente sparsità strutturale ($66,3\%$ di celle NaN nei dati grezzi) e della propagazione controllata LOCF adottata nel livello silver.

1.3 Impostazione architetturale e struttura dell'elaborato

Il sistema è stato progettato seguendo il paradigma dell'**architettura medallion**, che organizza il percorso dei dati in tre livelli progressivi denominati **bronze**, **silver** e **gold**. Questa separazione netta tra l'acquisizione immutabile dei tracciati grezzi, la fase intermedia di pulizia e arricchimento su disco locale e lo strato finale di servizio sul database ha garantito la piena riproducibilità degli esperimenti: ogni modifica alle regole di filtraggio degli outlier o di imputazione temporale ha potuto essere applicata rigenerando i livelli silver e gold a partire dai file locali in pochi minuti, senza mai ripetere il lento scaricamento di rete dai server di VitalDB.

Per la memorizzazione su disco nei primi due livelli è stato adottato il formato colonnare binario **Apache Parquet** al posto dei tradizionali file testuali CSV, ottenendo una forte riduzione dello spazio occupato, il mantenimento nativo dei tipi numerici in virgola mobile a 64 bit e la possibilità di partizionare fisicamente i file del livello silver in sottocartelle per reparto chirurgico (`department=<REPARTO>`). Lo strato gold è stato invece affidato a una collezione temporale nativa di **MongoDB 8.0** (`vital_signals`), che raggruppa i secondi contigui dello stesso paziente in blocchi compressi chiamati **bucket**, indicizza i metadati clinici e omette fisicamente le chiavi dei parametri non misurati in un dato istante.

Sulla collezione temporale di MongoDB è stato inoltre costruito a livello applicativo un sistema di **data governance** ispirato ai moderni **data lakehouse**. Strumenti industriali come Delta Lake, Apache Iceberg o Apache Hudi offrono transazioni atomiche e cataloghi distribuiti su file Parquet, ma richiedono motori di calcolo come Apache Spark o Trino che risulterebbero sproporzionati per gestire 500 casi su un singolo nodo e non opererebbero direttamente dentro le collezioni temporali di MongoDB. Le garanzie di integrità, tracciabilità delle esecuzioni tramite `run_id` e recupero automatico da arresti anomali sono state quindi implementate combinando una collezione di catalogo (`registry`) validata da uno schema formale con un protocollo di caricamento a due fasi in Python.

Sopra il livello gold opera infine un motore di **anomaly detection** ibrido che unisce due regole mediche deterministiche, basate sullo **shock index** e sull'ipotensione severa corretta per l'età della misura pressoria, con due algoritmi di **machine learning** non supervisionato, ovvero un modello ad alberi **isolation forest** e una rete neurale ricorrente **autoencoder LSTM** realizzata in PyTorch. L'intera piattaforma è esposta tramite un servizio REST sviluppato con **FastAPI** e

una dashboard web interattiva in HTML5, CSS3 e JavaScript, il tutto racchiuso in due container **Docker** orchestrati automaticamente.

L'esposizione dei capitoli successivi ricalca il flusso logico appena tracciato: il **Capitolo 2** dettaglia l'implementazione dei livelli bronze e silver e la trasformazione dei dati da tabella Parquet a documento BSON; il **Capitolo 3** approfondisce l'archiviazione sul livello gold in MongoDB 8.0, i risultati sperimentali sui tempi di risposta e sullo spazio su disco e i meccanismi di governance; il **Capitolo 4** descrive la formulazione delle regole cliniche, l'ingegnerizzazione delle feature, i modelli non supervisionati e la loro valutazione; il **Capitolo 5** illustra infine i servizi API, l'interfaccia grafica, la suite di test automatici e un bilancio critico dei limiti architetturali con i possibili sviluppi futuri.

Capitolo 2

Architettura della pipeline dati

2.1 Il modello medallion a tre livelli

Per elaborare oltre cinque milioni di secondi di monitoraggio biometrico mantenendo una distinzione rigorosa tra il dato originale e le trasformazioni successive, la pipeline è stata strutturata secondo il modello dell'**architettura medallion**, articolato nei tre livelli **bronze**, **silver** e **gold**.

Invece di scaricare i tracciati dall'interfaccia remota di VitalDB, applicare le correzioni in memoria centrale e inserire direttamente i record nel database, ogni livello persiste il proprio stato con un ruolo ben delimitato: il **livello bronze** ha il compito esclusivo di acquisire e congelare su disco locale i tracciati grezzi esattamente come vengono restituiti dalla sorgente, senza filtrare né alterare alcun campione; il **livello silver** legge i file grezzi locali, individua i valori fisiologicamente fuori scala, applica le regole di imputazione differenziate per ciascun segnale, arricchisce le righe con i flag di qualità e organizza i file in partizioni fisiche per reparto chirurgico; il **livello gold** converte infine le tabelle bonificate in documenti gerarchici BSON e li carica nella collezione temporale di MongoDB 8.0, rendendoli disponibili per le interrogazioni dell'interfaccia web e per gli algoritmi di rilevamento delle anomalie. L'architettura complessiva della pipeline e il relativo flusso sequenziale di elaborazione, dall'ingestione remota alla visualizzazione nella dashboard web, sono illustrati nella Figura 2.1.

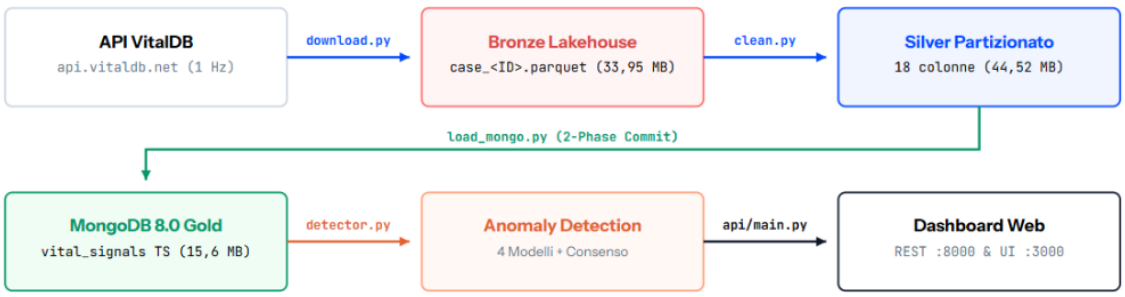


Figura 2.1: Architettura end-to-end della pipeline dati e flusso di elaborazione: ingestione bronze, bonifica silver, caricamento gold su MongoDB 8.0, rilevamento delle anomalie e interfaccia web.

2.2 Livello bronze: acquisizione e storicizzazione dei dati grezzi

Il primo stadio della pipeline è realizzato nello script `src/bronze/download.py`. All'avvio, la funzione `find_available_cases` interroga il catalogo remoto tramite il metodo `vitaldb.find_cases(tracks)` per individuare gli interventi chirurgici in cui sono simultaneamente presenti tutte e cinque le tracce richieste (`HR`, `PLETH_SPO2`, `NIBP_SBP`, `NIBP_DBP` e `NIBP_MBP`). Sull'insieme restituito viene selezionato il perimetro configurato tramite la costante `MAX_CASES = 500` definita in `src/config.py` e, per ciascun intervento, la funzione `download_case` scarica la matrice numerica campionata a passo costante di un secondo (`SAMPLING_INTERVAL = 1.0`), aggiunge l'asse temporale relativo `Time` e salva il risultato nel percorso `data/bronze/case_<ID>.parquet`. Per evitare

che un'interruzione improvvisa lasci sul disco file incompleti o illeggibili, il salvataggio avviene sempre su un file temporaneo con suffisso `.tmp`, che viene rinominato in modo atomico nella destinazione definitiva solo al termine della scrittura.

La scelta di adottare **Apache Parquet** fin dal livello bronze risponde a precise esigenze di efficienza: memorizzare $5,56$ milioni di righe distribuite su 500 file CSV testuali avrebbe comportato un consumo elevato di spazio su disco, tempi lunghi di scansione lessicale e la necessità di ridedurre ad ogni lettura i tipi numerici in virgola mobile (`float64`). Grazie alla codifica colonnare binaria compressa con algoritmo Snappy, l'intero archivio bronze dei 500 pazienti occupa appena **33,95 MB** e viene riletto in memoria da `pandas.read_parquet` in pochi millisecondi preservando lo schema esatto delle colonne.

Accanto alle serie temporali dei singoli interventi, il modulo bronze acquisisce due tabelle di contesto ospedaliero applicando politiche di gestione degli errori differenziate in base alla criticità del dato per gli stadi successivi. Per i metadati anagrafici e clinici salvati in `clinical_data.parquet`, indispensabili per conoscere età, sesso e soprattutto il reparto chirurgico `department` di ciascun paziente, la funzione `download_clinical_data` adotta una politica di arresto immediato (**fail-fast**). Durante lo sviluppo si è infatti riscontrato che la funzione `vitaldb.load_clinical_data()` della libreria ufficiale, se invocata senza argomenti, restituisce una tabella vuota a causa di un difetto interno del package; lo script interroga quindi direttamente l'endpoint HTTP `https://api.vitaldb.net/cases` e utilizza la chiamata parametrizzata con la lista esplicita degli identificativi (`caseids=list(range(1, 6389))`) come secondo tentativo. Qualora entrambi i canali fallissero, l'esecuzione viene interrotta immediatamente con `sys.exit(1)`, evitando che il livello silver successivo partizioni silenziosamente tutti i pazienti dentro una cartella residuale `department=UNKNOWN`. Al contrario, per i referti ematochimici salvati in `lab_data.parquet` tramite la funzione `download_lab_data`, viene applicata una politica di tolleranza (**graceful fallback**): poiché le analisi di laboratorio sono storicizzate nel livello bronze per completezza documentale ma non entrano nel calcolo delle anomalie a 1 Hz, un'eventuale indisponibilità del servizio remoto viene annotata con stato `unavailable` senza bloccare la pipeline.

Ogni esecuzione di `download.py` genera infine un identificativo univoco tramite la funzione `config.get_or_create_run_id(force_new=True)`, memorizzato nel file `data/.current_run_id` e riportato nel registro `data/download_manifest.json` insieme alla versione della pipeline (`pipeline_version: "1.1.0"`), all'intervallo di campionamento e all'esito dettagliato di ciascuno dei 500 casi (`downloaded`, `skipped_existing` oppure `failed`). Quando lo script viene rilanciato su una cartella già popolata, prima di contrassegnare un file esistente come `skipped_existing` apre il relativo Parquet e verifica che contenga tutte le colonne attese e che la distanza temporale tra i primi due campioni (`Time.iloc[1] - Time.iloc[0]`) coincida esattamente con il passo di $1,0$ s.

2.3 Livello silver: bonifica fisiologica, imputazione e partizionamento

I tracciati grezzi storicizzati nel livello bronze presentano una frazione complessiva di celle mancanti (`NaN`) pari al $66,3\%$, oltre a valori incompatibili con la fisiologia umana generati da artefatti sui sensori. Il modulo `src/silver/clean.py` trasforma ciascun caso applicando una sequenza ordinata di operazioni che bonifica le serie storiche senza distruggere le evidenze degli errori strumentali. All'avvio, la funzione `process_all_cases` legge il perimetro dei casi attivi da `download_manifest.json` e rimuove preventivamente dalla cartella `data/silver/` eventuali file Parquet residui appartenenti a esecuzioni precedenti configurate con un numero differente di pazienti, garantendo che i conteggi globali riflettano sempre e solo la coorte corrente.

Un aspetto metodologico cruciale riguarda il mantenimento della griglia temporale regolare a

1 Hz durante l'intero processo di pulizia. Se si eliminassero le righe completamente vuote all'inizio dell'elaborazione tramite `dropna(how='all')`, due campioni separati da dieci minuti di disconnessione dei sensori diventerebbero righe adiacenti nella tabella; di conseguenza, i successivi algoritmi di interpolazione e propagazione basati sul numero di righe agirebbero su intervalli temporali distorti. Nella funzione `clean_case` la griglia completa a passo di un secondo viene quindi preservata fino al termine di tutti i calcoli, scartando le righe in cui tutti e cinque i parametri vitali sono simultaneamente nulli (`dropna(subset=vital_cols, how='all')`) soltanto come ultima istruzione. Sulla coorte di 500 interventi, questa scelta comporta la rimozione di **162.998 righe inattive su 5.565.384** (**2,93%**), corrispondenti quasi interamente ai minuti iniziali e finali di sala operatoria in cui il monitor è acceso ma i cavi non sono ancora collegati al paziente.

Prima di procedere al riempimento dei dati mancanti, lo script identifica gli artefatti strumentali confrontando ciascun canale con gli intervalli di validità fisiologica centralizzati nel dizionario `TRACK_SPECS` del modulo `src/config.py`, riportati nella Tabella 2.1. L'adozione di un'unica sorgente configurativa nel codice Python ha permesso di eliminare alla radice i disallineamenti che si erano verificati nelle prime versioni del progetto, quando i limiti erano duplicati manualmente tra gli script di pulizia e gli script di inizializzazione del database.

Traccia VitalDB	Flag di qualità nel livello silver	Intervallo valido (TRACK_SPECS)	Unità
`Solar8000/HR`	`HR_outlier`, `HR_imputed`	$20 - 250$	bpm
`Solar8000/PLETH_SPO2`	`SPO2_outlier`, `SPO2_imputed`	$50 - 100$	%
`Solar8000/NIBP_SBP`	`SBP_outlier`, `SBP_imputed`	$40 - 250$	mmHg
`Solar8000/NIBP_DBP`	`DBP_outlier`, `DBP_imputed`	$10 - 180$	mmHg
`Solar8000/NIBP_MBP`	`MBP_outlier`, `MBP_imputed`	$20 - 220$	mmHg

Tabella 2.1: Intervalli di validità fisiologica definiti in `TRACK_SPECS` e relativi flag associati nel livello silver.

Quando un valore osservato cade al di fuori dell'intervallo indicato nella Tabella 2.1, il dato grezzo non viene cancellato dalla tabella, ma viene conservato per finalità di ispezione clinica impostando a `True` il corrispondente flag booleano `*_outlier`. Questa verifica viene eseguita rigorosamente sui dati grezzi prima di qualsiasi imputazione temporale e, durante il calcolo delle interpolazioni e delle propagazioni in avanti, le celle marcate come outlier vengono temporaneamente mascherate a `NaN` (`raw_col.mask(out_mask)`). Se gli outlier venissero calcolati dopo la propagazione in avanti, una singola lettura errata del bracciale pressorio (ad esempio una pressione sistolica pari a 10 mmHg) verrebbe infatti replicata per i cinque minuti successivi e conteggiata erroneamente come trecento anomalie strumentali consecutive.

Una volta isolati gli artefatti, l'imputazione dei valori mancanti viene differenziata in funzione della fisica dei sensori. Per i segnali continui ad alta frequenza, ovvero `HR` e `PLETH_SPO2`, viene utilizzata la funzione `interpolate_short_gaps(series, max_gap=5)`. A differenza del metodo standard `.interpolate(limit=5)` di Pandas, che riempie comunque i primi cinque secondi anche all'inizio di una lunga disconnessione del sensore generando una coda artificiale, la funzione implementata misura preliminarmente l'ampiezza di ciascuna sequenza di `NaN` e ricostruisce per interpolazione lineare esclusivamente le interruzioni interne di durata inferiore o uguale a 5 secondi comprese tra due letture valide, registrando l'operazione nei flag `HR_imputed` e `SPO2_imputed`.

Per le tre componenti della pressione arteriosa non invasiva (`NIBP_SBP`, `NIBP_DBP` e `NIBP_MBP`), campionate fisiologicamente ogni 2–5 minuti, viene invece applicata la tecnica del mantenimento dell'ultima osservazione valida (**last observation carried forward**, o LOCF) tramite `ffill(limit=300)`, propagando in avanti l'ultima lettura non-outlier per un orizzonte massimo di 300 secondi. Oltre i cinque minuti senza un nuovo gonfiaggio del bracciale il segnale tor-

na a `NaN`, poiché in ambito anestesiologico una misura pressoria troppo datata cessa di essere rappresentativa dello stato emodinamico corrente. Per tracciare in modo esplicito l'invecchiamento del dato pressorio istante per istante, in ogni riga viene calcolata la variabile `nibp_age_s` come differenza tra il secondo corrente e l'istante dell'ultima acquisizione reale del bracciale ($\texttt{nibp_age_s} = t - t_{\text{last_cuff}}$), assegnando il valore sentinella `9999.0` ai secondi iniziali dell'intervento che precedono la prima misurazione valida. L'efficacia complessiva di questo trattamento sul segnale cardiaco è visibile nella Figura 2.2, mentre l'implementazione della logica di pulizia è riportata nel Listato 2.1.

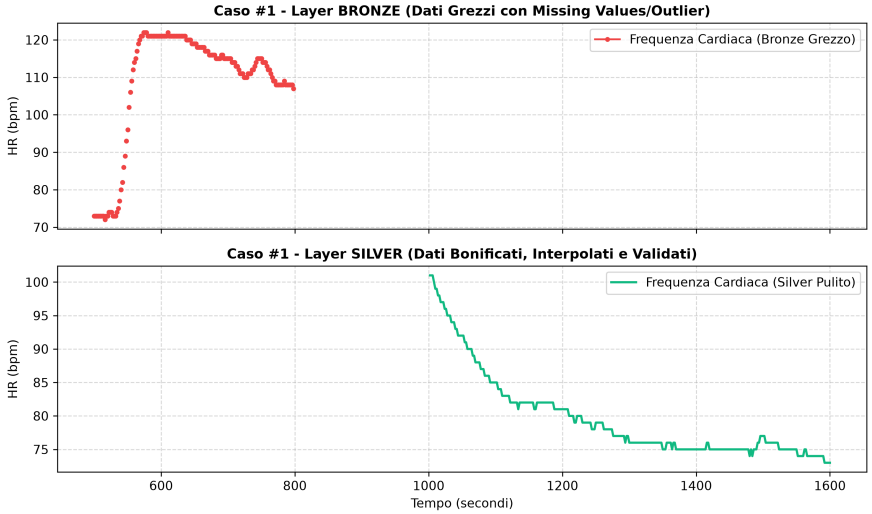


Figura 2.2: Confronto tra il tracciato grezzo della frequenza cardiaca nel livello bronze e il segnale bonificato nel livello silver.

```
// Codice estratto da src/silver/clean.py
# 1. Flag outlier calcolati sui dati grezzi (da config.TRACK_SPECS) prima di imputare
for track_name, flag_col in outlier_map.items():
    spec = track_specs.get(track_name, {})
    val = df_clean[track_name]
    df_clean[flag_col] = val.notna() & ((val < spec["min"]) | (val > spec["max"]))

# 2. Segnali continui (HR e SpO2): interpola solo buchi interni <= 5s senza propagare outlier
clean_hr, hr_imp = interpolate_short_gaps(raw_hr.mask(out_hr), max_gap=5)
df_clean['Solar8000/HR'] = clean_hr.where(~out_hr, raw_hr)
df_clean['HR_imputed'] = hr_imp & (~out_hr)

# 3. Segnali NIBP: calcolo nibp_age_s (sentinella 9999.0) e LOCF max 300s per traccia
last_measure_time = time_series.where(any_valid_nibp).ffill()
df_clean['nibp_age_s'] = (time_series - last_measure_time).fillna(9999.0).astype(float)
for t, o, imp_col in present_nibp:
    raw_col = df_clean[t]
    out_mask = df_clean[o]
    was_na = raw_col.isna()
    filled_col = raw_col.mask(out_mask).ffill(limit=300)
    df_clean[t] = filled_col.where(~out_mask, raw_col)
    df_clean[imp_col] = was_na & df_clean[t].notna()

# 4. Scarta solo alla fine le righe con tutte e 5 le tracce vitali contemporaneamente nulle
df_clean = df_clean.dropna(subset=vital_cols, how='all').copy()
```

Listato 2.1: Rilevamento preventivo degli outlier, interpolazione dei buchi brevi e propagazione LOCF in `src/silver/clean.py`.

Al termine della bonifica, le tabelle vengono salvate su disco organizzandole in sottocartelle secondo la convenzione di partizionamento Hive:

`data/silver/department=<REPARTO>/case_<ID>.parquet`

L'associazione tra ciascun `case_id` e il reparto di appartenenza avviene interrogando `clinical_data.parquet`, avendo cura di convertire gli identificativi da `numpy.int64` al tipo `int` nativo di Python per garantire la corrispondenza esatta delle chiavi nel dizionario di mappatura. Il partizionamento fisico per reparto chirurgico consente di eseguire analisi selettive su specifiche specialità (come chirurgia generale o chirurgia toracica) leggendo dal disco unicamente la sottocartella interessata. Contestualmente, lo script genera il resoconto globale `data/quality_report.json` e archivia la copia dell'esecuzione precedente nella cartella storica `data/quality_history/`.

2.4 Evoluzione del modello dati da tabella Parquet a documento BSON

L'attraversamento dei tre livelli dell'architettura medallion comporta una progressiva evoluzione della struttura e della rappresentazione fisica dei dati, riassunta visivamente insieme alle quattro regole di bonifica nella Figura 2.3. Nel livello bronze ogni file Parquet presenta una struttura tabellare minima composta da **6 colonne**, corrispondenti all'istante temporale `Time` e alle cinque tracce biometriche grezze. Passando al livello silver, la tabella si espande a **18 colonne**: alle

sei variabili originarie si affiancano l'identificativo `case_id`, i cinque flag booleani di anomalia strumentale (`HR_outlier`, `SPO2_outlier`, `SBP_outlier`, `DBP_outlier`, `MBP_outlier`), i cinque flag booleani di ricostruzione temporale (`HR_imputed`, `SPO2_imputed`, `SBP_imputed`, `DBP_imputed`, `MBP_imputed`) e il contatore continuo di invecchiamento pressorio `nibp_age_s`. Proprio l'introduzione di queste dodici colonne aggiuntive di tracciabilità, unita alla sostituzione di milioni di celle `NaN` con valori numerici propagati tramite LOCF, spiega per quale motivo i file Parquet del livello silver occupino su disco più spazio rispetto al livello bronze (**44,52 MB** contro **33,95 MB**, con un incremento del **31,1%**).



Figura 2.3: Sintesi delle quattro regole di bonifica non distruttiva nel livello silver ed evoluzione dello schema dati da 6 colonne Parquet a documento gerarchico BSON.

Nel passaggio finale al livello gold, realizzato dalla funzione `build_records` in `src/gold/load_mongo.py`, la rappresentazione tabellare lascia il posto al modello documentale gerarchico **BSON** proprio di MongoDB 8.0, riducendo l'occupazione fisica dei dati a **15,60 MB**. Come illustrato nel Listato 2.2, ciascun secondo attivo viene strutturato in quattro sezioni distinte: il campo radice `timestamp`, ottenuto convertendo i secondi relativi `Time` in un oggetto `ISODate` riferito alla data convenzionale `2020-01-01T00:00:00Z`; il sotto-documento `metadata`, che raccoglie gli attributi invarianti del paziente (`case_id`, `sensor_name`, `department`, `age` e `sex`) e funge da chiave di raggruppamento (`metaField`) per i bucket della collezione temporale; il dizionario `metrics`, che memorizza le misure fisiologiche sostituendo il carattere `/` con `_` nei nomi delle chiavi e omettendo fisicamente qualsiasi parametro risultato nullo in quel secondo; e infine il sotto-documento `quality_flags`, che preserva tutti i dieci flag booleani e l'età `nibp_age_s` a beneficio dei moduli di rilevamento delle anomalie a valle.

```
// Documento BSON archiviato nella collezione 'vital_signals'
{
  "_id": ObjectId("65d3f1a0e4b01a2b3c4d5e6f"),
  "timestamp": ISODate("2020-01-01T08:15:30Z"),
  "metadata": {
    "case_id": 1,
    "sensor_name": "Solar8000",
    "department": "General surgery",
    "age": 64,
    "sex": "M"
  },
  "metrics": {
    "Solar8000_HR": 72.0,
    "Solar8000_PLETH_SPO2": 98.0,
    "Solar8000_NIBP_SBP": 120.0,
    "Solar8000_NIBP_DBP": 80.0,
    "Solar8000_NIBP_MBP": 93.3
  },
  "quality_flags": {
    "HR_outlier": false, "SPO2_outlier": false,
    "SBP_outlier": false, "DBP_outlier": false, "MBP_outlier": false,
    "HR_imputed": false, "SPO2_imputed": false,
    "SBP_imputed": true, "DBP_imputed": true, "MBP_imputed": true,
    "nibp_age_s": 14.0
  }
}
```

Listato 2.2: Struttura del documento BSON inserito nella collezione temporale `vital_signals` del livello gold.

Capitolo 3

Archiviazione e governance con MongoDB Time Series

3.1 Archiviazione temporale nel livello gold

Il livello **gold** costituisce lo strato di persistenza progettato per servire con bassa latenza le interrogazioni della dashboard web, le rotte dell'interfaccia REST e il caricamento dei dati verso i modelli di apprendimento automatico. Nel progetto sono state confrontate tre opzioni architetturali per questo livello: mantenere i dati unicamente su file Parquet, soluzione ottima per letture sequenziali ma poco adatta a un servizio web che deve filtrare singoli pazienti, calcolare medie su finestre temporali variabili e salvare contemporaneamente le anomalie rilevate; utilizzare una collezione MongoDB standard o una tabella relazionale classica, scelta che su $5,4$ milioni di secondi avrebbe generato un elevato consumo di spazio e di memoria per via della duplicazione delle chiavi e delle voci di indice su ogni singolo secondo; oppure adottare le collezioni temporali native (**time series**) di **MongoDB 8.0**.

La scelta è ricaduta su quest'ultima soluzione, implementata nello script `src/gold/load_mongo.py` mediante la collezione `vital_signals`. Dichiarando la collezione come serie temporale nella funzione `ensure_timeseries_collections(db)`, il motore di archiviazione WiredTiger non memorizza un documento fisico indipendente per ogni secondo, ma raccoglie automaticamente le misure contigue appartenenti allo stesso paziente all'interno di contenitori compressi denominati **bucket**, gestiti nella collezione interna `system.buckets.vital_signals`. La configurazione poggia su tre parametri: `timeField: "timestamp"`, che definisce l'asse temporale di ordinamento; `metaField: "metadata"`, che raggruppa i campioni per paziente (`case_id`, `sensor_name`, `department`, `age` e `sex`) e costruisce automaticamente un indice composto su metadati e tempo; e `granularity: "seconds"`, che calibra l'ampiezza dei bucket per serie acquisite alla frequenza di 1 Hz (fino a mille campioni o un'ora di registrazione per blocco).

All'interno di ciascun bucket, MongoDB organizza i campi in forma colonnare applicando algoritmi di compressione specifici per il tipo di dato. I valori temporali vengono codificati con lo schema **Delta-of-Delta**: poiché i campioni del monitor `Solar8000` sono distanziati di un secondo costante ($D_i = t_i - t_{i-1} = 1$ s), la differenza seconda $\Delta_i = D_i - D_{i-1}$ risulta quasi ovunque nulla e richiede un singolo bit anziché 64 bit per ogni istante. Le serie numeriche in virgola mobile vengono invece compresse tramite codifica differenziale XOR sulle mantisse IEEE 754 seguita dall'algoritmo **Zstandard**, particolarmente efficace su segnali come frequenza cardiaca e saturazione che variano gradualmente da un secondo al successivo. A questo si aggiunge il vantaggio dell'omissione nativa dei campi assenti in BSON: mentre un file Parquet deve allocare i livelli di definizione per segnalare se una cella è piena o vuota, quando la pressione arteriosa risulta `NaN` la funzione `build_records` non scrive la chiave corrispondente nel dizionario `metrics`, azzerando l'occupazione fisica dei campioni mancanti.

3.2 Analisi sperimentale di spazio su disco, latenza e valori mancanti

Per valutare quantitativamente il comportamento dei tre livelli sulla coorte di 500 pazienti è stato realizzato il modulo `src/analysis/benchmark_etl.py`, che salva le misurazioni nel file `data/benchmark_report.json` associandovi gli identificativi `run_id` e `pipeline_version` (`"1.1.0"`). Per garantire un confronto omogeneo tra file system e database, lo script interroga preliminarmente il catalogo `registry` prelevando la lista dei **500 casi con stato** `committed` ($5.402.386$ secondi attivi) e calcola le dimensioni su disco filtrando esattamente i medesimi cinquecento identificativi nei livelli bronze e silver. I risultati sperimentali sono riportati nella Tabella 3.1 e rappresentati graficamente nella Figura 3.1.

Metrica sperimentale	Bronze (Parquet, 6 col.)	Silver (Parquet, 18 col.)	Gold (MongoDB 8.0)
Occupazione su disco (500 casi)	33,95 MB	44,52 MB (+31,1% con flag)	**15,60 MB** (-54,1% vs bronze / -65,0% vs silver)
Indici B-Tree (`totalIndexSize`)	non applicabile	non applicabile	+2,56 MB (totale `collStats`: 18,16 MB)
Latenza query singolo caso	26,95 ms (Parquet)	26,95 ms (Parquet)	**12,02 ms** (indice su `metaField`)
Fattore di velocizzazione	1,0× (riferimento)	1,0×	**2,2× più veloce**
Valori mancanti (tasso di null)	66,3%	26,3% (dopo LOCF)	26,3% logico / **0 byte fisici**

Tabella 3.1: Confronto sperimentale di spazio su disco, latenza di interrogazione e valori mancanti sui 500 casi clinici.

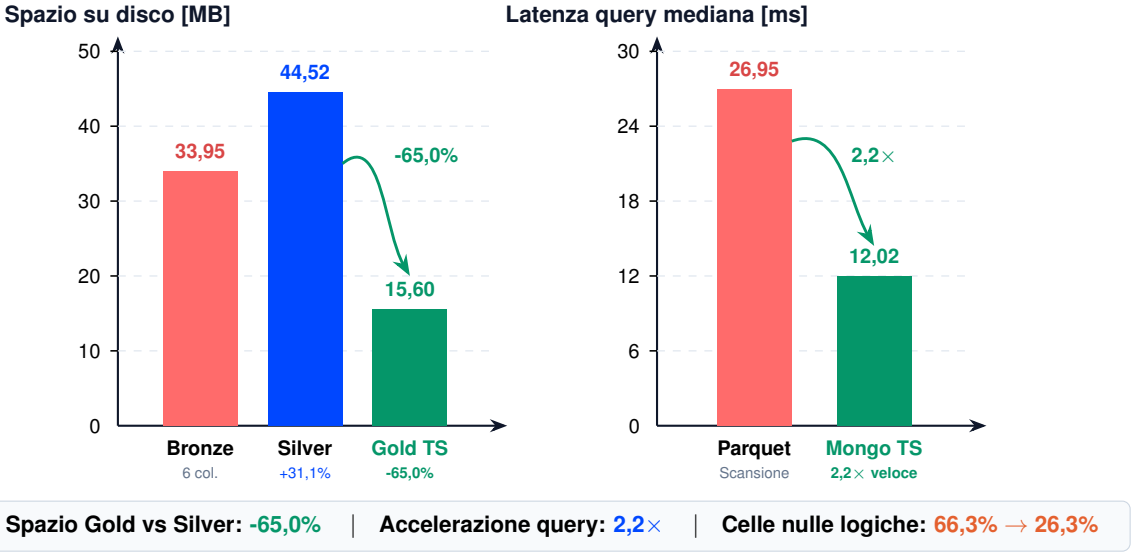


Figura 3.1: Confronto grafico dell'occupazione su disco, dei tempi di risposta e degli indicatori sintetici sui 500 interventi chirurgici.

L'osservazione congiunta della Tabella 3.1 e della Figura 3.1 mette in luce la diversa funzione svolta dai livelli silver e gold. Nel passaggio dal livello bronze al livello silver il volume complessivo su disco cresce da **33,95 MB** a **44,52 MB** (**+31,1%**): questo incremento deriva dall'espansione dello schema da 6 a 18 colonne e dal riempimento delle lacune pressorie tramite LOCF, che riduce i valori mancanti dal $66,3\%$ al $26,3\%$. In particolare, il contatore `nibp_age_s` è memorizzato come numero in virgola mobile a 64 bit che si incrementa di un'unità ad ogni secondo $(0, 1, 2, \ldots, 300)$, impedendo al compressore di Parquet di sfruttare la ripetizione di valori uguali consecutivi. Quando i medesimi dati vengono trasferiti nella collezione temporale del livello gold, la compressione per bucket di MongoDB riduce lo spazio fisico dei dati (`storageSize`) a **15,60 MB**, segnando un risparmio del **65,0%** rispetto a silver e del **54,1%** rispetto a bronze; includendo an-

che i **2,56 MB** occupati dagli indici B-Tree (`totalIndexSize`), l'impronta totale della collezione si attesta a **18,16 MB**.

Anche il calcolo del tasso di valori mancanti nel livello gold merita una precisazione metodologica. Poiché nei documenti BSON le chiavi corrispondenti a misure assenti vengono omesse, una verifica puramente sintattica restituirebbe zero campi nulli; per ottenere una misura fedele dal punto di vista informativo, `benchmark_etl.py` esegue una query con l'operatore `$exists` su ciascuna delle cinque metriche vitali rapportando le occorrenze effettive al totale teorico di documenti $\times 5$. Il valore risultante del **26,3%**, identico a quello misurato sui file Parquet del livello silver, conferma che la trasformazione in BSON non altera in alcun modo il contenuto informativo pur azzerando il costo di archiviazione dei campioni mancanti.

Sul fronte delle prestazioni di lettura, il benchmark confronta a parità di operazione il tempo necessario per calcolare la frequenza cardiaca media dell'intervento `case_id = 1`. Dopo un ciclo preliminare di riscaldamento della cache, la mediana calcolata su 15 esecuzioni consecutive mostra che la lettura e l'aggregazione del file Parquet partizionato richiedono **26,95 ms**, mentre la pipeline di aggregazione MongoDB composta dagli stadi `$match` su `metadata.case_id` e `$group` completa il calcolo in **12,02 ms**, risultando **2,2 volte più veloce** grazie all'accesso diretto ai soli bucket del paziente richiesto tramite l'indice sul `metaField`.

3.3 Architettura di data governance e gestione transazionale

Per garantire che i dati esposti nel livello gold siano completi, conformi allo schema atteso e ricollegabili ai file locali da cui derivano, è stato progettato un sistema di **data governance** applicativo che riproduce i meccanismi essenziali di un **data lakehouse** direttamente su MongoDB 8.0 e Python, senza introdurre dipendenze da motori distribuiti come Apache Spark, Delta Lake o Apache Iceberg. La Tabella 3.2 sintetizza come ciascuna garanzia tipica di un lakehouse industriale sia stata tradotta nella nostra architettura.

3.3.1 Catalogo dei casi, contratti di schema e metadati delle tracce

Il fulcro dell'architettura di controllo è costituito dalla collezione `registry`, che mantiene un documento di stato per ciascuno dei 500 casi clinici del livello gold. Ogni voce generata dalla funzione `build_registry_doc` in `src/gold/load_mongo.py` memorizza l'identificativo `case_id`, la versione dello schema (`schema_version: "1.0"`), lo stato corrente del caricamento (`status`, che può assumere i valori `loading`, `committed` oppure `failed`), il conteggio esatto dei secondi inseriti (`record_count`), i riferimenti `run_id` e `pipeline_version` e il sotto-documento `provenance`, nel quale sono registrati l'istante UTC di caricamento, i parametri di pulizia applicati (`max_gap_seconds: 5.0`, `nibp_staleness_limit_s: 300.0`, `sampling_interval_s: 1.0`) e il riepilogo delle metriche di qualità per sensore (`sensor_metrics`).

A livello di database, lo script di inizializzazione `mongo/registry_schema.js` impone sulla collezione `registry` un vincolo formale tramite l'operatore nativo `$jsonSchema` configurato con `validationLevel: "strict"` e `validationAction: "error"`, come mostrato nel Listato 3.1. In questo modo il motore di MongoDB rifiuta automaticamente qualsiasi inserimento o aggiornamento che risulti privo degli attributi obbligatori `case_id`, `schema_version` e `provenance` o che presenti tipi di dato difformi da quelli dichiarati.

Requisito di governance	Implementazione su MongoDB e Python	Differenza rispetto a Delta Lake / Iceberg
Registro delle transazioni e isolamento dei lettori	Collezione `registry` con stati `loading` → `committed` / `failed` e filtro `{"status": "committed"}` su tutte le letture.	Coordinamento applicativo in due fasi anziché transazione atomica nativa del motore di storage, assistito da `recover_incomplete_loads`.
Validazione dello schema e contratto dati	Validatore nativo `$jsonSchema` su `registry` e controllo preventivo `validate_records(records)` prima di `insert_many` su `vital_signals`.	MongoDB 8.0 non supporta `$jsonSchema` sulle collezioni temporali, rendendo necessario il controllo lato Python per `vital_signals`.
Catalogo dei metadati fisiologici	Dizionario `TRACK_SPECS` in `src/config.py` sincronizzato nella collezione `track_metadata` da `seed_track_metadata(db)`.	Sincronizzazione automatica ad ogni esecuzione di `load_mongo.py` senza necessità di un metastore esterno separato.
Tracciabilità delle esecuzioni	Identificativi `run_id` e `pipeline_version` condivisi nei quattro file JSON e nel `registry`, con storico in `quality_history/`.	Tracciabilità mantenuta a livello di caso nel catalogo `registry` per non appesantire i singoli documenti temporali.

Tabella 3.2: Confronto tra i meccanismi di un data lakehouse industriale e l'implementazione realizzata su MongoDB 8.0.

```
// Schema definito in mongo/registry_schema.js
db.runCommand({
    collMod: "registry",
    validator: {
        $jsonSchema: {
            bsonType: "object",
            required: ["case_id", "schema_version", "provenance"],
            properties: {
                case_id: { bsonType: ["int", "long"], description: "ID caso VitalDB" },
                schema_version: { bsonType: "string", description: "Versione schema" },
                record_count: { bsonType: ["int", "long"], description: "Secondi caricati" },
                provenance: {
                    bsonType: "object",
                    required: ["step", "timestamp"],
                    properties: {
                        step: { bsonType: "string" },
                        timestamp: { bsonType: "date" }
                    }
                }
            }
        }
    },
    validationLevel: "strict",
    validationAction: "error"
});
```

Listato 3.1: Regola di validazione `$jsonSchema` applicata alla collezione `registry` in `mongo/registry_schema.js`.

Accanto al catalogo dei pazienti, la collezione `track_metadata` conserva il dizionario descrittivo delle cinque tracce del monitor `Solar8000`, specificando per ciascuna l'unità di misura (`bpm`, `%`, `mmHg`), il significato clinico e l'intervallo fisiologico ammesso (`expected_range`). Poiché il container Docker di MongoDB esegue gli script presenti in `/docker-entrypoint-initdb.d/` soltanto al primo avvio assoluto su volume vuoto, una modifica successiva alle soglie nel codice Python rischierebbe di non riflettersi nel database; per evitare qualsiasi disallineamento, all'inizio di ogni esecuzione di `process_silver_to_gold` viene invocata la funzione `seed_track_metadata(db)`, che rilegge il dizionario `config.TRACK_SPECS` ed esegue un'operazione di `update_one(..., upsert=True)` su ciascuna traccia, mantenendo il catalogo sul database costantemente sincronizzato con la configurazione applicativa.

Per la contabilizzazione della qualità dei dati, salvata sia in `data/quality_report.json` sia nel campo `sensor_metrics` di ciascun documento del `registry`, tutti gli indicatori vengono calcolati sullo stesso denominatore di righe attive bonificate `rows_cleaned` (`rows_after`). Su ciascuno dei cinque canali viene così garantita l'identità esatta:

$$\texttt{observed} + \texttt{imputed} + \texttt{missing} \equiv \texttt{rows_cleaned}$$

nella quale `imputed` corrisponde alla somma del flag booleano dedicato (`HR_imputed`, `SPO2_imputed`, `SBP_imputed`, `DBP_imputed` o `MBP_imputed`), `observed` misura i campioni acquisiti direttamente dal sensore e `missing` conta i valori `NaN` residui. Da queste tre grandezze vengono infine derivate la percentuale di letture dirette $\texttt{observed_pct} = \frac{\texttt{observed}}{\texttt{rows_cleaned}} \times 100$, la copertura complessiva disponibile dopo l'imputazione $\texttt{coverage_pct} = \frac{\texttt{observed}+\texttt{imputed}}{\texttt{rows_cleaned}} \times 100$ e la copertura rapportata alla durata grezza iniziale del file bronze $\texttt{temporal_coverage_bronze_pct} = \frac{\texttt{observed}+\texttt{imputed}}{\texttt{rows_original}} \times 100$.

3.3.2 Protocollo di caricamento a due fasi e recupero automatico

L'implementazione del caricamento verso il livello gold ha richiesto di affrontare due restrizioni architetturali proprie delle collezioni temporali di MongoDB 8.0: da un lato, il motore del database non consente di inserire documenti in una collezione time series all'interno di una transazione multi-documento ACID, restituendo l'errore nativo 263 (`OperationNotSupportedInTransaction`); dall'altro, non permette di associare un validatore `$jsonSchema` lato server alla collezione `vital_signals`.

Per garantire comunque l'integrità dei dati e l'isolamento dei lettori senza ricorrere a transazioni native, in `src/gold/load_mongo.py` è stato sviluppato un protocollo applicativo a due fasi abbinato a una validazione preventiva in memoria, il cui flusso operativo complessivo insieme ai tre pilastri di compressione dei bucket è rappresentato nella Figura 3.2. Prima di avviare qualsiasi scrittura sul database, la funzione `validate_records(records)` ispeziona tutti i documenti generati per il paziente verificando che `timestamp` sia un oggetto `datetime` valido, che `metadata.case_id` sia un intero nativo, che `metadata.sensor_name` sia una stringa non vuota e che tutti i valori contenuti in `metrics` siano numeri finiti privi di `NaN`, sollevando un'eccezione `ValueError` in caso di violazione.

Superato il controllo in memoria, la funzione `load_case_to_mongo` avvia la prima fase scrivendo nel catalogo `registry` un documento con stato `status: "loading"` e `record_count: 0`, seguito immediatamente dalla rimozione preventiva di eventuali punti pregressi del medesimo paziente tramite `db['vital_signals'].delete_many({"metadata.case_id": int(case_id)})`. Nella seconda fase viene eseguito l'inserimento massivo `db['vital_signals'].insert_many(records)`: se l'operazione termina correttamente, il documento nel `registry` viene promosso allo stato `status: "committed"` aggiornando il conteggio finale dei record e i metadati di provenienza; se invece si verifica un errore `PyMongoError`, il blocco di gestione delle eccezioni elimina subito i punti parziali appena in-

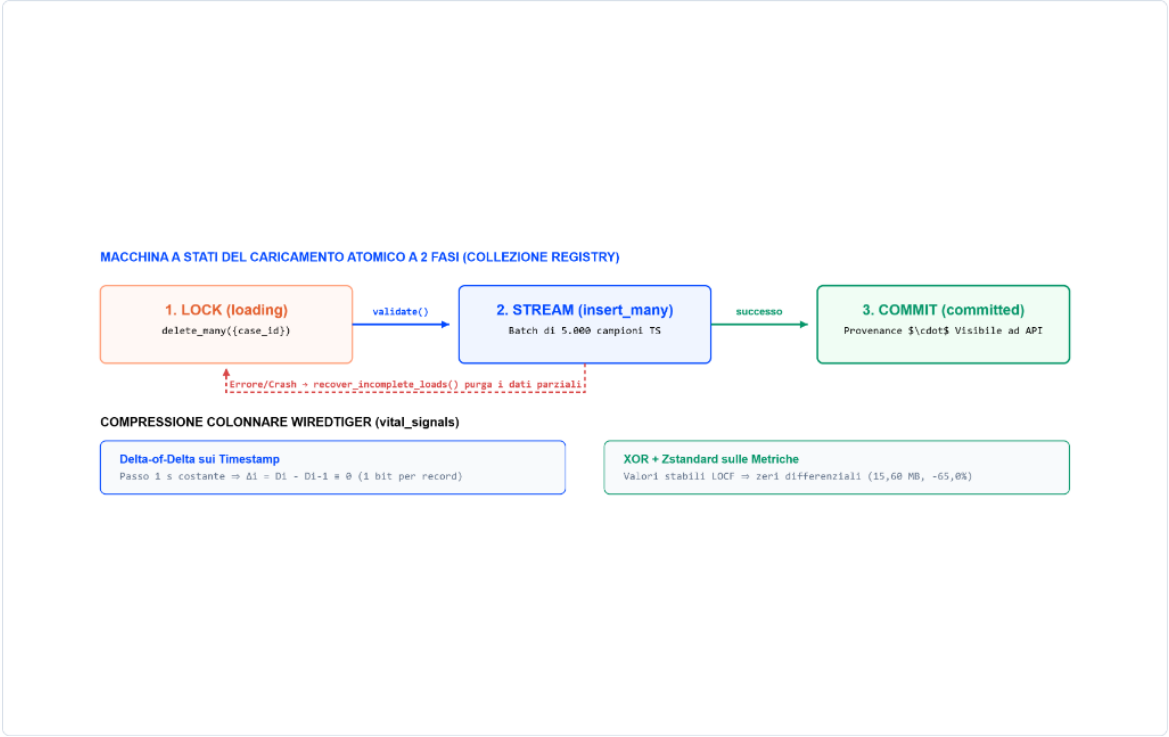


Figura 3.2: Meccanismi di compressione dei bucket nella collezione `vital_signals` e macchina a stati per il caricamento atomico a due fasi gestita tramite il catalogo `registry`.

seriti in `vital_signals` e marca il caso con `status: "failed"` annotando il messaggio diagnostico nel campo `last_error`.

Qualora il processo Python o il container venissero interrotti bruscamente da un segnale esterno (come `SIGKILL` o una caduta di alimentazione) prima dell'esecuzione del blocco di compensazione, al successivo avvio dello script interviene automaticamente la funzione `recover_incomplete_loads(db, active_case_ids)`: essa individua nel `registry` tutti i casi rimasti in uno stato diverso da `committed`, rimuove i relativi campioni orfani da `vital_signals` ed elimina inoltre dal database eventuali pazienti che non appartengono più al perimetro silver corrente. Poiché tutti i moduli di lettura a valle interrogano il catalogo applicando il filtro `{"status": "committed"}`, nessun caso incompleto o fallito può mai essere letto dall'API o dai modelli di rilevamento.

3.4 Pipeline di aggregazione e ottimizzazione delle interrogazioni

Per mantenere fluida l'interazione sulla dashboard web anche quando si esplorano interventi chirurgici della durata di molte ore, le operazioni di riduzione temporale e di recupero dei metadati sono state delegate direttamente al motore di aggregazione di MongoDB nel modulo `src/analysis/queries.py`. Un intervento di sei ore a 1 Hz comprende oltre ventimila documenti temporali: trasferire sistematicamente l'intera serie grezza via HTTP verso il browser appesantirebbe il disegno dei grafici quando l'utente desidera osservare l'andamento complessivo dell'operazione.

La funzione `downsample_case(db, case_id, window_seconds)` risolve il problema eseguendo sul database la pipeline a quattro stadi riportata nel Listato 3.2. Il primo stadio `$match` seleziona i bucket del singolo paziente sfruttando l'indice su `metadata.case_id`; il secondo stadio `$group` applica l'operatore nativo `$dateTrunc` per discretizzare l'asse temporale in finestre regolari di ampiezza configurabile (30, 60 oppure 300 secondi) calcolando con `$avg` il valore medio dei cinque

parametri vitali in ciascun intervallo; gli stadi finali `$project` e `$sort` riformattano l'istante iniziale della finestra nel campo `window_start` e restituiscono la sequenza ordinata cronologicamente.

```
// Pipeline eseguita da downsample_case() in src/analysis/queries.py
pipeline = [
    {"$match": {"metadata.case_id": case_id}},
    {
        "$group": {
            "_id": {
                "$dateTrunc": {
                    "date": "$timestamp",
                    "unit": "second",
                    "binSize": window_seconds
                }
            },
            "Solar8000_HR":         {"$avg": "$metrics.Solar8000_HR"},
            "Solar8000_PLETH_SPO2": {"$avg": "$metrics.Solar8000_PLETH_SPO2"},
            "Solar8000_NIBP_SBP":   {"$avg": "$metrics.Solar8000_NIBP_SBP"},
            "Solar8000_NIBP_DBP":   {"$avg": "$metrics.Solar8000_NIBP_DBP"},
            "Solar8000_NIBP_MBP":   {"$avg": "$metrics.Solar8000_NIBP_MBP"},
        }
    },
    {"$project": {"_id": 0, "window_start": "$_id", ...}},
    {"$sort": {"window_start": 1}}
]
```

Listato 3.2: Pipeline di aggregazione con operatore `$dateTrunc` per la riduzione temporale in `src/analysis/queries.py`.

Un'ulteriore ottimizzazione riguarda il popolamento della barra laterale dei pazienti nella dashboard tramite la rotta `GET /cases`, che deve mostrare per tutti i 500 interventi l'identificativo, il conteggio dei punti, il reparto chirurgico, l'età e il sesso. Poiché i documenti della collezione `registry` contengono `case_id` e `record_count` ma non i dati anagrafici, un'implementazione ingenua eseguirebbe prima una query sul catalogo e poi 500 interrogazioni `find_one` distinte su `vital_signals` (schema $N + 1$ pari a 501 chiamate di rete). Nel file `api/main.py` il caricamento è stato invece ricondotto a due sole interrogazioni complessive: una lettura dei casi `committed` da `registry` tramite `list_loaded_cases(db)` e un'unica pipeline di aggregazione su `vital_signals` con stadio `$group` su `$metadata.case_id` e operatore `$first` sui campi `department`, `age` e `sex`, unendo infine i due dizionari in memoria centrale.

Capitolo 4

Modelli di anomaly detection

4.1 Impostazione dell'approccio ibrido

Nel monitoraggio intraoperatorio un paziente può andare incontro a instabilità emodinamica attraverso dinamiche molto eterogenee: in alcuni casi si assiste alla variazione acuta e repentina di un singolo parametro vitale, come un crollo improvviso della saturazione o della pressione arteriosa, mentre in altre situazioni il deterioramento si manifesta con oscillazioni più lente e distribuite contemporaneamente su più segnali. Nella progettazione del modulo di rilevamento delle anomalie, implementato in `src/detection/detector.py`, il primo vincolo strutturale è rappresentato dall'assenza nel dataset VitalDB di annotazioni cliniche secondo per secondo certificate da un medico anestesista, circostanza che esclude la possibilità di addestrare classificatori supervisionati tradizionali.

D'altra parte, l'impiego esclusivo di regole mediche a soglia fissa oppure di soli algoritmi di apprendimento non supervisionato presenterebbe limiti opposti. Le regole cliniche deterministiche possiedono un significato fisiologico immediato e trasparente per il personale sanitario, ma osservano una o due variabili per volta in modo statico e si attivano soltanto quando la soglia critica è già stata oltrepassata. Al contrario, i modelli di **machine learning** non supervisionato sono in grado di ispezionare congiuntamente tutte le variabili biometriche e le loro derivate temporali senza richiedere etichette di addestramento, ma producono un punteggio di atipicità statistica che da solo non distingue un'emergenza clinica da una variazione benigna del tracciato.

Per coniugare interpretabilità medica e capacità di analisi multivariata, è stata quindi adottata una strategia ibrida articolata su quattro metodi complementari, sintetizzati nella Figura 4.1: due regole cliniche deterministiche dominio-specifiche, basate sullo **shock index** (SI $> 0,9$) e sull'**ipotensione severa concomitante a ipossiemia** (MBP < 65 mmHg $\wedge$ $SpO_2 < 90\%$), affiancate da due modelli di apprendimento non supervisionato operanti su uno spazio a otto dimensioni, ovvero l'algoritmo ad alberi **isolation forest** e una rete neurale ricorrente **autoencoder LSTM** realizzata in PyTorch. L'abbinamento tra un modello basato sul partizionamento casuale dello spazio delle feature e un'architettura ricorrente su finestre scorrevoli di 30 secondi consente di confrontare un rilevatore puntuale molto rapido con un modello capace di catturare le dipendenze sequenziali nel tempo.

4.2 Estrazione dal livello gold e formulazione delle regole cliniche

Prima di applicare le regole e i modelli, la funzione `load_from_gold(db, case_ids)` in `src/detection/detector.py` preleva le serie temporali dal livello gold adottando tre accorgimenti essenziali per la tenuta della memoria e la correttezza clinica. In primo luogo, la funzione interroga il catalogo `registry` selezionando unicamente i pazienti con stato `committed` e, quando il numero di interventi richiesti supera le 25 unità (come nell'elaborazione dell'intera coorte da 500 casi), suddivide la lettura da `vital_signals` in blocchi da `batch_size = 25` pazienti tramite la funzione ausiliaria `_fetch_gold_batch`, ordinando ciascun blocco per `("metadata.case_id", 1)` e `("timestamp", 1)` così da evitare picchi di allocazione nel cursore PyMongo su $5,4$ milioni di

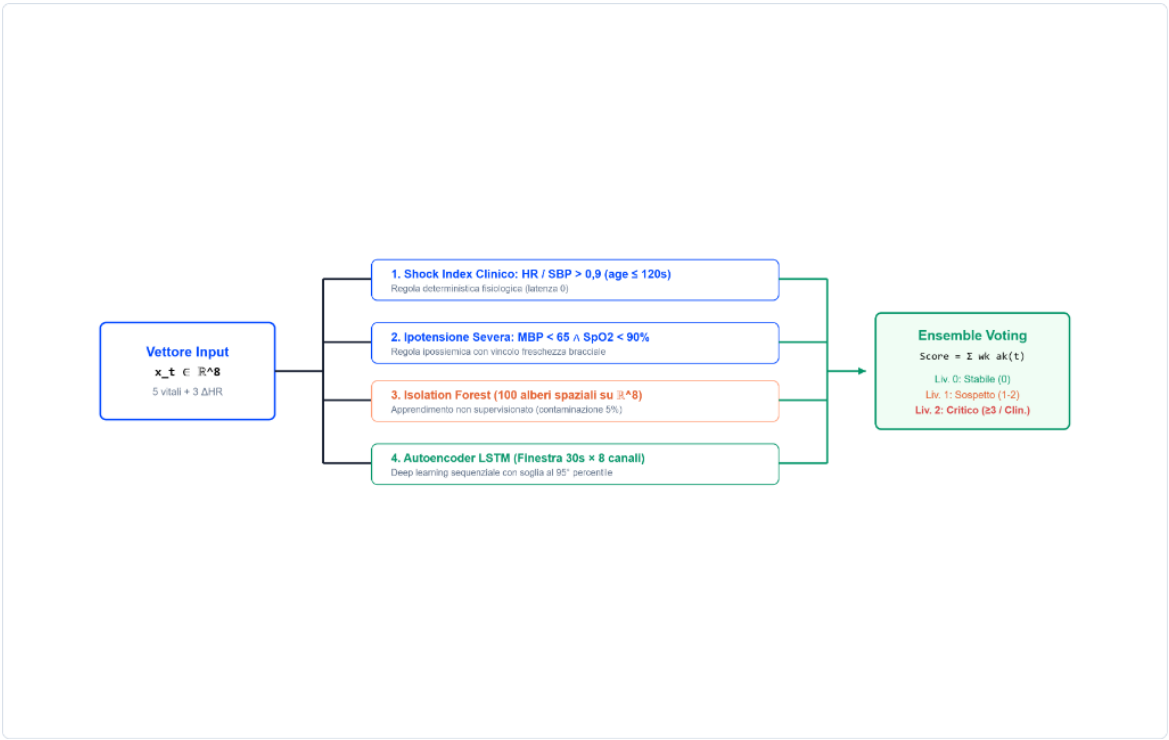


Figura 4.1: Quadro sinottico del motore di rilevamento ibrido a quattro metodi che combina due regole cliniche deterministiche a latenza zero con due modelli non supervisionati.

documenti.

In secondo luogo, la funzione esegue il mascheramento attivo degli artefatti strumentali: poiché il livello silver mantiene i valori grezzi fuori scala per finalità di tracciabilità limitandosi a segnalarli nei flag booleani `quality_flags.*_outlier`, `load_from_gold` legge ciascuno dei cinque flag e sostituisce in memoria i campioni corrispondenti con `np.nan` prima di calcolare qualsiasi indice, impedendo che un disturbo da elettrobisturi (HR $= 320$ bpm) generi falsi allarmi a cascata. Infine, viene introdotto un vincolo rigoroso sulla freschezza della misura pressoria per le regole cliniche. Mentre nel livello silver le letture intermittenti del bracciale vengono propagate in avanti fino a 300 secondi per fornire una matrice densa ai modelli multivariati, sul piano medico non sarebbe corretto mantenere attivo un allarme acuto basandosi su una pressione rilevata quattro o cinque minuti prima. Entrambe le regole cliniche leggono quindi il contatore `quality_flags.nibp_age_s` e applicano la soglia configurata in `config.NIBP_MAX_CLINICAL_AGE_S = 120.0` secondi, valutando il dato pressorio solo se acquisito negli ultimi due minuti.

La prima regola deterministica calcola lo **shock index** (SI), un indicatore emodinamico adimensionale impiegato in anestesia e rianimazione per intercettare stati di shock ipovolemico o emorragico incipiente, definito dal rapporto tra la frequenza cardiaca e la pressione arteriosa sistolica:

$$\mathrm{SI} = \frac{\text{Solar8000_HR}}{\text{Solar8000_NIBP_SBP}}$$

In condizioni fisiologiche stabili il rapporto si colloca tra $0,5$ e $0,7$; in presenza di ipovolemia o marcata vasodilatazione da farmaci anestetici, l'organismo attiva una tachicardia compensatoria mentre la pressione sistolica flette, spingendo l'indice verso l'alto. La funzione `compute_shock_index(df, threshold=0.9, max_nibp_age_s=None)`, dopo aver convertito a `np.nan` eventuali valori non positivi del denominatore, contrassegna come anomalo ogni secondo che soddisfa la

condizione:

$$\text{SI} > 0,9 \quad \wedge \quad \texttt{nibp_age_s} \leq 120 \text{ s}$$

La seconda regola clinica, implementata nella funzione `compute_severe_hypotension(df, mbp_threshold=65.0, spo2_threshold=90.0, max_nibp_age_s=None)`, individua gli episodi critici in cui un'ipoperfusione arteriosa severa si manifesta simultaneamente a una desaturazione periferica d'ossigeno:

$$\text{Solar8000_NIBP_MBP} < 65 \text{ mmHg} \wedge \text{Solar8000_PLETH_SPO2} < 90\% \wedge \texttt{nibp_age_s} \leq 120 \text{ s}$$

Il contemporaneo superamento verso il basso della soglia di perfusione d'organo (65 mmHg) e della soglia ipossiemica (90%) su una misura pressoria fresca identifica infatti una condizione di immediata sofferenza ipossica-ischemica dei tessuti.

4.3 Ingegnerizzazione delle feature temporali e imputazione locale

Se i modelli di apprendimento automatico ricevessero in ingresso soltanto i cinque parametri biometrici istantanei, un algoritmo privo di memoria sequenziale come isolation forest tratterebbe ogni secondo come un punto indipendente, senza poter distinguere una frequenza cardiaca stabile a 95 bpm da un battito che è appena salito bruscamente da 60 a 95 bpm in pochi istanti. Per incorporare nel vettore di stato anche la dinamica locale senza moltiplicare eccessivamente il numero di dimensioni, nella funzione `run_detection_pipeline` vengono calcolate tre feature derivate a partire dal segnale più continuo e affidabile della coorte, ovvero la frequenza cardiaca `Solar8000_HR` campionata a 1 Hz. Indicando con x_t il valore di frequenza cardiaca al secondo t e adottando una finestra mobile retrospettiva di ampiezza $W = 5$ secondi (`rolling(5, min_periods=1)`), lo script ricava la media mobile a cinque secondi `HR_rolling_mean` che smorza le fluttuazioni istantanee:

$$\mu_t = \frac{1}{W} \sum_{k=0}^{W-1} x_{t-k}$$

la deviazione standard mobile `HR_rolling_std` (inizializzata a `0.0` sul primo campione di ciascun intervento) che quantifica la variabilità a brevissimo termine del ritmo cardiaco:

$$\sigma_t = \sqrt{\frac{1}{W-1} \sum_{k=0}^{W-1} (x_{t-k} - \mu_t)^2}$$

e infine la differenza prima `HR_delta` (`.diff().fillna(0.0)`), che misura la velocità di variazione istantanea da un secondo al successivo:

$$\Delta x_t = x_t - x_{t-1}$$

Tutte e tre le trasformazioni vengono eseguite raggruppando la tabella per paziente tramite l'espressione `df.groupby("case_id", sort=False)["Solar8000_HR"]`, evitando qualsiasi contaminazione tra gli ultimi campioni di un intervento e i primi secondi del paziente successivo. Lo spazio delle variabili fornito ai modelli non supervisionati risulta così formato da **8 feature numeriche**: i cinque canali biometrici (`Solar8000_HR`, `Solar8000_PLETH_SPO2`, `Solar8000_NIBP_SBP`, `Solar8000_NIBP_DBP` e `Solar8000_NIBP_MBP`) uniti alle tre grandezze dinamiche (`HR_rolling_mean`, `HR_rolling_std` e `HR_delta`), escludendo volutamente `nibp_age_s` poiché rappresenta un contatore tecnico del bracciale e non una variabile fisiologica del paziente.

Poiché né l'implementazione di `IsolationForest` in scikit-learn né i tensori di PyTorch ammettono valori `NaN` in ingresso, prima dell'addestramento è necessario completare le eventuali lacune

residue (come i periodi in cui il bracciale pressorio è rimasto inattivo per oltre 300 secondi o i campioni appena mascherati perché outlier). Durante lo sviluppo si è individuato e corretto un sottile difetto legato al concatenamento dei metodi in Pandas: scrivendo `df.groupby("case_id")[feat_cols].ffill().bfill()`, il primo `.ffill()` opera correttamente all'interno di ciascun paziente ma restituisce un `DataFrame` ordinario non più raggruppato, per cui il successivo `.bfill()` finiva per propagare all'indietro i valori del paziente seguente qualora i primi minuti di un intervento fossero privi di letture pressorie. La correzione, applicata in tutti i moduli di rilevamento e di valutazione e presidiata dal test unitario `test_imputation_no_bfill_leakage_across_cases`, riapplica esplicitamente il raggruppamento per `case_id` anche nella propagazione all'indietro:

```
df.groupby("case_id", sort=False)[feat_cols].ffill().groupby(df["case_id"], sort=False).bfill().fillna(0.0)
```

confinando rigorosamente ogni imputazione all'interno del singolo caso clinico.

4.4 Modelli non supervisionati: isolation forest e autoencoder LSTM

4.4.1 Partizionamento casuale nello spazio a otto dimensioni con isolation forest

Il primo modello di apprendimento non supervisionato, implementato nella funzione `detect_isolation_forest(df, contamination=0.05)`, impiega l'algoritmo **isolation forest** della libreria scikit-learn (`random_state=42`). Invece di stimare la densità locale dei campioni normali, operazione computazionalmente onerosa su $5,4$ milioni di righe, l'algoritmo costruisce un insieme di alberi binari di isolamento selezionando ricorsivamente in modo casuale una delle otto feature e un valore di taglio compreso tra il minimo e il massimo. I campioni fisiologici regolari, addensati attorno al centro della distribuzione multivariata, richiedono numerose partizioni successive prima di essere isolati in una foglia; al contrario, i punti che presentano valori estremi o combinazioni inusuali tra le otto variabili (come un'elevata instabilità `HR_rolling_std` associata a una flessione della pressione media) vengono separati dal resto della coorte in pochissimi tagli vicino alla radice dell'albero, ottenendo una lunghezza media del cammino ridotta e un punteggio di anomalia elevato.

Impostando l'iperparametro `contamination=0.05` (così come la soglia al 95° percentile nel successivo modello neurale), l'algoritmo ordina tutti i secondi analizzati dal più regolare al più atipico ed etichetta come anomalo il 5% dei campioni situati nella coda estrema della distribuzione. Quando la pipeline viene eseguita sull'intera coorte di 500 pazienti, il taglio del 5% viene applicato sulla distribuzione globale dei punteggi, facendo sì che gli interventi clinicamente più turbolenti concentrino una quota maggiore di segnalazioni rispetto ai pazienti emodinamicamente stabili.

4.4.2 Architettura ricorrente dell'autoencoder LSTM e gestione della memoria

Per intercettare anomalie che si sviluppano come sequenze temporali anomale anziché come singoli picchi istantanei, il secondo modello adotta un **autoencoder LSTM** realizzato in PyTorch, che analizza finestre scorrevoli di **30 secondi consecutivi** su tutte le otto feature standardizzate con `StandardScaler` (media nulla e varianza unitaria). Come illustrato nella Figura 4.2 e nel Listato 4.1, la rete neurale `_LSTMAutoencoder` riceve in ingresso un tensore tridimensionale di forma $(B, 30, 8)$ e lo comprime attraverso un codificatore ricorrente `nn.LSTM(n_features=8, hidden_size=32, batch_first=True)` in un vettore di contesto latente h a 32 dimensioni; tale rappresentazione compressa viene replicata per tutti i 30 passi temporali della finestra e inviata al decodificatore `nn.LSTM(32, 32, batch_first=True)`.

All'uscita del decodificatore è stato inserito uno strato di proiezione lineare `self.out = nn.Linear(32, 8)`. Questa scelta progettuale risolve un limite intrinseco delle celle LSTM



Figura 4.2: Architettura della rete autoencoder LSTM a sette stadi con proiettore lineare e calcolo dell'errore massimo sui canali.

standard, la cui uscita passa attraverso una funzione di attivazione tangente iperbolica ($\tanh$) limitata all'intervallo $[-1, +1]$: poiché le otto feature standardizzate in punteggio Z assumono regolarmente valori superiori a ± 2 o ± 3 durante le oscillazioni fisiologiche, l'assenza del proiettore lineare finale impedirebbe fisicamente alla rete di ricostruire i valori oltre l'unità.

```python
def _make_lstm_autoencoder_class():
    """Costruisce la classe LSTMAutoencoder come nn.Module solo se PyTorch e' disponibile."""
    if not _TORCH_AVAILABLE:
        return None

    class _LSTMAutoencoder(nn.Module):
        def __init__(self, n_features, hidden_size=32, n_layers=1):
            super().__init__()
            # Encoder LSTM: comprime la sequenza in un vettore latente
            self.encoder = nn.LSTM(n_features, hidden_size, n_layers, batch_first=True)
            # Decoder LSTM: decodifica il vettore latente nello spazio nascosto
            self.decoder = nn.LSTM(hidden_size, hidden_size, n_layers, batch_first=True)
            # Layer di proiezione lineare: mappa lo stato nascosto nello spazio continuo R^n
            self.out = nn.Linear(hidden_size, n_features)

        def forward(self, x):
            # x ha forma (batch, T, n_features)
            _, (hidden, _) = self.encoder(x)
            # Ripete il vettore latente per ogni timestep della sequenza
            context = hidden.permute(1, 0, 2).repeat(1, x.size(1), 1)
            output, _ = self.decoder(context)
            return self.out(output)  # dimensione: (batch, T, n_features)

    return _LSTMAutoencoder
```

Listato 4.1: Definizione della rete PyTorch `_LSTMAutoencoder` con proiettore lineare in `src/detection/detector.py`.

Passando dai primi collaudi su piccola scala all'intera coorte di **500 interventi** ($5.402.386$ secondi), la generazione di finestre scorrevoli di ampiezza 30 e passo 1 produce circa $5,39$ milioni di matrici di dimensione $(30, 8)$: materializzare tutte le finestre in un unico array tridimensionale tramite `np.concatenate` avrebbe richiesto oltre **5,17 GB** di memoria RAM in `float32`, causando l'arresto del container Docker per esaurimento della memoria. Nella classe `LSTMAutoencoderDetector` il problema è stato risolto combinando tre tecniche. In primo luogo, il metodo `_make_window_views_per_case` converte i dati normalizzati in `np.float32` e costruisce per ciascun paziente una vista virtuale senza copia in memoria tramite `np.lib.stride_tricks.sliding_window_view(vals, window_shape=(30, 8))`, che modifica unicamente i passi di indicizzazione (**stride**) sull'array bidimensionale esistente evitando anche di creare finestre a cavallo tra due pazienti diversi. In secondo luogo, quando il numero complessivo di finestre supera `max_train = 15000`, la fase di addestramento estrae dalle viste un sottocampione uniforme di 15.000 finestre distribuite lungo l'intera coorte (`np.linspace(0, total_windows - 1, max_train, dtype=int)`), che occupa appena **14,4 MB** di RAM, addestrando la rete per 5 epoche con ottimizzatore Adam (`lr=1e-3`). Infine, la fase di inferenza valuta comunque tutte le $5,39$ milioni di finestre scorrendo le viste virtuali a blocchi di `eval_batch_size = 4096` elementi dentro un contesto `torch.no_grad()`.

Anche la metrica con cui viene sintetizzato l'errore di ricostruzione di ciascuna finestra è stata oggetto di affinamento. Poiché le tre tracce pressorie rimangono costanti per lunghi tratti per effetto della propagazione LOCF, l'autoencoder impara a ricostruirle con errore prossimo allo zero; se si calcolasse la media aritmetica dell'errore quadratico su tutte e otto le colonne, il crollo improvviso di un singolo canale vitale come la saturazione SpO_2 verrebbe diviso per otto

e mascherato dagli altri sette canali stabili. Per evitare questa diluizione, lo script calcola prima l'errore quadratico medio temporale sui 30 secondi di ciascuna variabile (`mean_time_err = torch.mean(sq_err, dim=1)`) e seleziona poi il **massimo errore tra gli otto canali** (`batch_mse, _ = torch.max(mean_time_err, dim=1)`):

$$\mathcal{E}(X) = \max_{c \in \{1,\dots,8\}} \left(\frac{1}{30} \sum_{t=1}^{30} (X_{t,c} - \hat{X}_{t,c})^2 \right)$$

Il punteggio $\mathcal{E}(X)$ di ciascuna finestra viene attribuito al suo ultimo secondo (`case_idx[self.window_size - 1:]`) ed etichetta come anomali gli istanti che superano il $95°$ percentile della distribuzione degli errori.

4.5 Valutazione sperimentale sui 500 casi e persistenza degli allarmi

Per analizzare il comportamento dei due modelli non supervisionati sull'intera coorte di 500 pazienti è stato predisposto il modulo `src/analysis/evaluate_models.py`, che salva i risultati in `data/ml_evaluation.json`. In assenza di annotazioni mediche esterne, lo script costruisce un riferimento interno (**pseudo-ground truth** clinica) definendo come istanti positivi i secondi in cui si attiva almeno una delle due regole cliniche deterministiche (shock index $> 0,9$ oppure ipotensione severa MBP < 65 mmHg $\wedge$ $SpO_2 < 90\%$, entrambe vincolate a `nibp_age_s` ≤ 120 s). Su un totale di **5.402.386 campioni** validati nel livello gold, le regole cliniche individuano **262.978 secondi positivi**, pari a una prevalenza (`base_rate_pct`) del **4,87%**.

Di fronte a una classe positiva pari al $4,87\%$ contro il $95,13\%$ di campioni stabili, l'accuratezza globale risulterebbe priva di valore informativo, poiché un classificatore banale che predicesse sempre la classe normale otterrebbe un'accuratezza del $95,13\%$ senza intercettare alcun evento critico. La valutazione utilizza quindi esclusivamente metriche specifiche per distribuzioni sbilanciate: **precision**, **recall**, **F1-score** sulla classe anomala e soprattutto l'area sotto la curva precisione-richiamo **PR-AUC** (`average_precision_score`), il cui valore di riferimento per un classificatore casuale coincide con la prevalenza della classe positiva ($0,0487$). I risultati sono riassunti nella Tabella 4.1.

Modello valutato	Precision (anom.)	Recall (anom.)	F1-score (anom.)	PR-AUC (media prec.)	Rapporto su base casuale
Classificatore casuale (riferimento)	0,000	0,000	0,000	0,049 (prevalenza 4,87%)	$1,0\times$
Isolation forest	**0,124**	**0,127**	**0,126**	**0,105**	$\approx 2,2\times$ **sopra il caso**
Autoencoder LSTM	0,096	0,098	0,097	0,067	$\approx 1,4\times$ **sopra il caso**

Tabella 4.1: Metriche di concordanza dei modelli non supervisionati rispetto alle regole cliniche sui 500 casi del livello gold.

I valori riportati nella Tabella 4.1 mostrano che **isolation forest** raggiunge una PR-AUC pari a **0,105** (circa $2,2$ volte superiore al riferimento casuale di $0,0487$, con F1-score pari a $0,126$), mentre l'**autoencoder LSTM** ottiene una PR-AUC di **0,067** (circa $1,4$ volte superiore al caso, con F1-score pari a $0,097$). L'entità contenuta di questi numeri in valore assoluto si spiega osservando la diversa natura dei segnali messi a confronto: le metriche non misurano la capacità dei modelli di replicare una diagnosi esterna, bensì il grado di sovrapposizione tra il 5% di campioni giudicati più atipici nello spazio a otto dimensioni e gli istanti in cui scattano due disuguaglianze statiche su sole tre variabili. Mentre le regole cliniche si disattivano completamente non appena l'età della misura pressoria supera i 120 secondi, i due modelli non supervisionati continuano ad analizzare la variabilità del battito (`HR_rolling_std`), le accelerazioni istantanee (`HR_delta`), la pressione diastolica e le sequenze di 30 secondi, segnalando come anomale anche brusche

aritmie o cadute pressorie che si arrestano appena sopra i 65 mmHg. Il fatto che isolation forest risulti più allineato alle regole rispetto all'autoencoder deriva proprio dal fatto che entrambi valutano il singolo secondo puntuale, laddove la rete ricorrente giudica la ricostruzione dell'intera finestra di 30 secondi. Se i modelli avessero mostrato una sovrapposizione prossima al 100% con le regole, avrebbero rappresentato un semplice duplicato computazionalmente costoso di due condizioni elementari; la loro parziale divergenza conferma invece la complementarità dei quattro indicatori, illustrata dalla distribuzione degli errori di ricostruzione nella Figura 4.3 e dalla matrice di concordanza nella Figura 4.4.

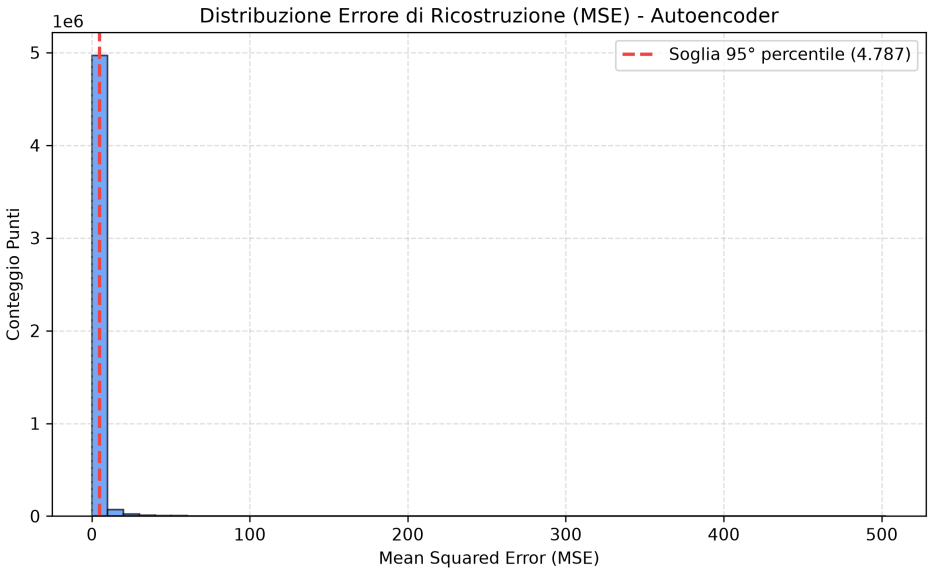


Figura 4.3: Distribuzione dell'errore di ricostruzione dell'autoencoder LSTM con soglia fissata al $95°$ percentile.

Al termine dell'elaborazione, la funzione `save_anomalies_to_mongo(db, df_anomalies)` archivia nella collezione `anomalies_detected` esclusivamente i secondi in cui almeno uno dei quattro metodi ha segnalato un'anomalia, memorizzando `case_id`, `timestamp`, la lista `methods` dei rilevatori attivati e l'istante di calcolo `detected_at`. Per evitare che un'interruzione dello script lasci la collezione vuota, invece di cancellare preventivamente i record pregressi viene adottato lo schema **insert-before-delete**: la funzione assegna a tutti i nuovi record del lotto un unico valore `now = datetime.now(timezone.utc)`, li inserisce a blocchi di ventimila documenti tramite `insert_many` e, solo dopo il completamento di tutte le scritture, rimuove per i casi analizzati i documenti appartenenti a esecuzioni precedenti aventi `detected_at` diverso da `now`.

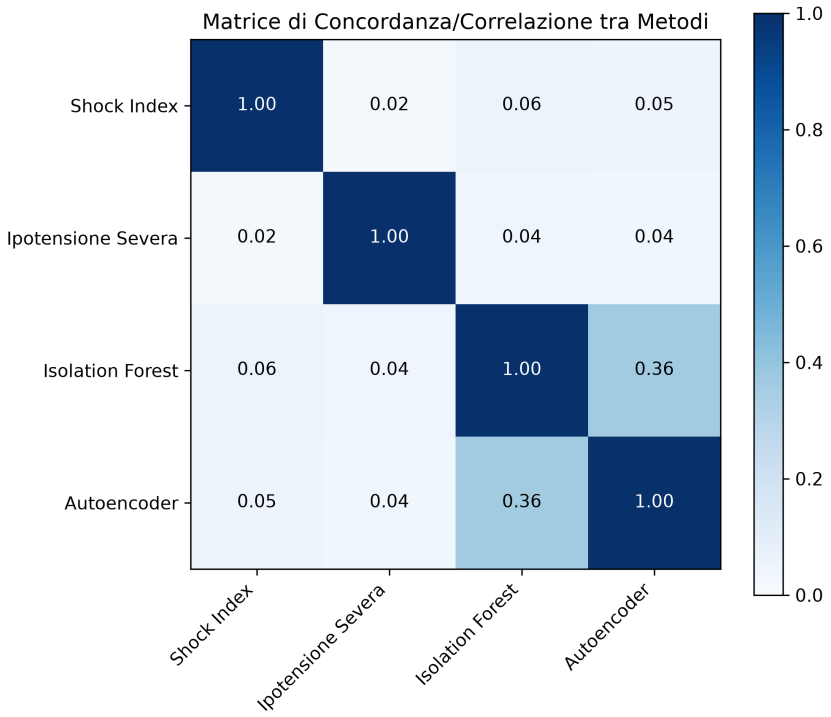


Figura 4.4: Matrice di concordanza tra le due regole cliniche deterministiche e i due modelli di machine learning.

Capitolo 5

Ingegnerizzazione del sistema, interfaccia grafica e conclusioni

5.1 Servizi REST con FastAPI

Per mettere in comunicazione il livello gold di MongoDB, il motore ibrido di rilevamento delle anomalie e l'interfaccia utente, è stato realizzato un servizio web REST in Python basato su **FastAPI**, definito nel modulo `api/main.py` ed eseguito all'interno del container Docker `vitaldb_api` sulla porta `8000`. L'adozione di FastAPI ha permesso di dichiarare le rotte HTTP con validazione automatica dei tipi per i parametri di percorso e di query (come `case_id: int` e `window_seconds: Optional[int]`), di esporre la documentazione interattiva OpenAPI all'indirizzo `http://localhost:8000/docs` e di montare tramite `StaticFiles` nello stesso processo `uvicorn` anche le cartelle statiche `/dashboard` e `/presentazione`, evitando l'aggiunta di un terzo container dedicato a un server web esterno.

Sul piano della gestione delle connessioni, il modulo mantiene un riferimento globale `_client: Optional[MongoClient] = None` inizializzato al primo utilizzo dalla funzione `get_db()`, consentendo a tutte le richieste HTTP concorrenti di condividere il medesimo pool di connessioni TCP di PyMongo verso il container `vitaldb_mongo`. Inoltre, prima di serializzare le risposte per il client, il backend converte sistematicamente eventuali valori `np.nan` residui di Pandas in oggetti `None` (tradotti nello standard JSON come `null`), garantendo la piena compatibilità con il parser nativo dei browser web.

L'interfaccia REST si articola su sette endpoint principali: la rotta diagnostica `GET /health` verifica il collegamento con MongoDB tramite comando `ping` e restituisce i conteggi dei documenti presenti in `registry`, `vital_signals` e `anomalies_detected`; la rotta `GET /cases` restituisce la lista dei 500 pazienti certificati con i relativi metadati anagrafici e di reparto; l'endpoint `GET /cases/{case_id}/series` fornisce la serie storica del singolo intervento a piena risoluzione (1 Hz) tramite `get_case_series` oppure ridotta su finestre temporali tramite `downsample_case` quando viene specificato il parametro `window_seconds`; le tre rotte `GET /quality`, `GET /benchmark` e `GET /evaluation` espongono infine i file JSON generati dagli script di analisi. A queste rotte di lettura si affianca l'endpoint `POST /cases/{case_id}/detect`, mostrato nel Listato 5.1, che avvia su richiesta l'analisi ibrida sul paziente selezionato invocando `run_detection_pipeline(db, [case_id])` e restituisce il riepilogo per metodo (`summary_by_method`) insieme al dettaglio cronologico dei secondi anomali.

```python
@app.post("/cases/{case_id}/detect")
def detect_case(case_id: int):
    """Esegue l'algoritmo multilivello di anomaly detection sul caso specificato."""
    db = get_db()
    df = run_detection_pipeline(db, [case_id])
    if df.empty:
        raise HTTPException(status_code=404, detail=f"Nessun dato per case_id={case_id}")

    flag_cols = [c for c in df.columns if c.endswith("_anomaly")]
    anomalous_rows = df[df[flag_cols].any(axis=1)]
    summary_by_method = {col.replace("_anomaly", ""): int(df[col].sum()) for col in flag_cols}

    def _val(row, col):
        return float(row[col]) if col in row and pd.notna(row[col]) else None

    anomalies = []
    for _, row in anomalous_rows.iterrows():
        methods = [c.replace("_anomaly", "") for c in flag_cols if bool(row[c])]
        si_val = _val(row, "shock_index")
        anomalies.append({
            "timestamp": str(row["timestamp"]),
            "methods": methods,
            "hr": _val(row, "Solar8000_HR"), "spo2": _val(row, "Solar8000_PLETH_SPO2"),
            "sbp": _val(row, "Solar8000_NIBP_SBP"), "dbp": _val(row, "Solar8000_NIBP_DBP"),
            "mbp": _val(row, "Solar8000_NIBP_MBP"),
            "shock_index": round(si_val, 3) if si_val is not None else None
        })

    return {
        "case_id": case_id,
        "anomaly_count": len(anomalies),
        "summary_by_method": summary_by_method,
        "anomalies": anomalies,
    }
```

Listato 5.1: Implementazione della rotta `POST /cases/{case_id}/detect` nel file `api/main.py`.

5.2 Dashboard web per l'esplorazione clinica e architetturale

L'interfaccia grafica del sistema, accessibile all'indirizzo `http://localhost:8000/dashboard`, è stata sviluppata utilizzando **HTML5, CSS3 e JavaScript standard** abbinati alla libreria **Chart.js** per la rappresentazione delle serie storiche, senza introdurre framework complessi come React o Angular che avrebbero richiesto una catena di compilazione Node.js dedicata dentro il container Docker. Per mantenere comunque il codice sorgente ordinato e diviso per responsabilità, lo script `dashboard/js/loader.js` carica dinamicamente all'avvio i frammenti HTML dichiarati tramite l'attributo `data-include` dentro `dashboard/index.html` (come la barra laterale, l'intestazione e le singole viste) utilizzando chiamate `fetch` parallele con parametro di versione `?v=3.9` per aggirare la cache del browser.

5.2.1 Vista di telemetria clinica e analisi del consenso

La prima vista dell'applicazione, gestita da `dashboard/js/app.js`, permette di ispezionare ciascuno dei 500 interventi della coorte confrontando le segnalazioni delle regole cliniche e dei modelli di apprendimento automatico. Come mostrato nella Figura 5.1 relativa al caso intraoperatorio #62, la barra laterale sinistra elenca i pazienti con stato `committed` offrendo una casella di ricerca testuale e filtri rapidi per reparto chirurgico. La sezione centrale superiore espone i dati anagrafici del paziente selezionato (età 47 anni, sesso femminile, chirurgia generale, 10.039 punti nel livello gold), il selettore della risoluzione temporale (`Raw 1s`, `30s`, `60s` e `5m`), i valori medi riassuntivi dei cinque parametri vitali e soprattutto la matrice di consenso tra i quattro metodi di rilevamento, nella quale ogni scheda riporta il conteggio degli eventi individuati (sul caso #62: 330 secondi per lo shock index, 0 per l'ipotensione severa, 502 per isolation forest e 501 per l'autoencoder LSTM, per un totale di 1.060 secondi anomali unici) e consente di filtrare visivamente i marker sui grafici sottostanti.

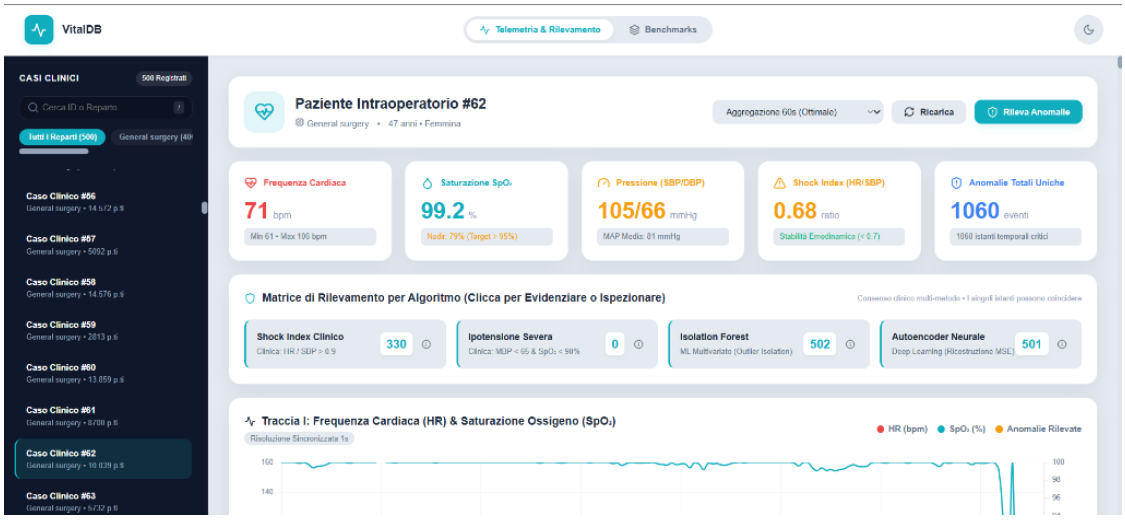
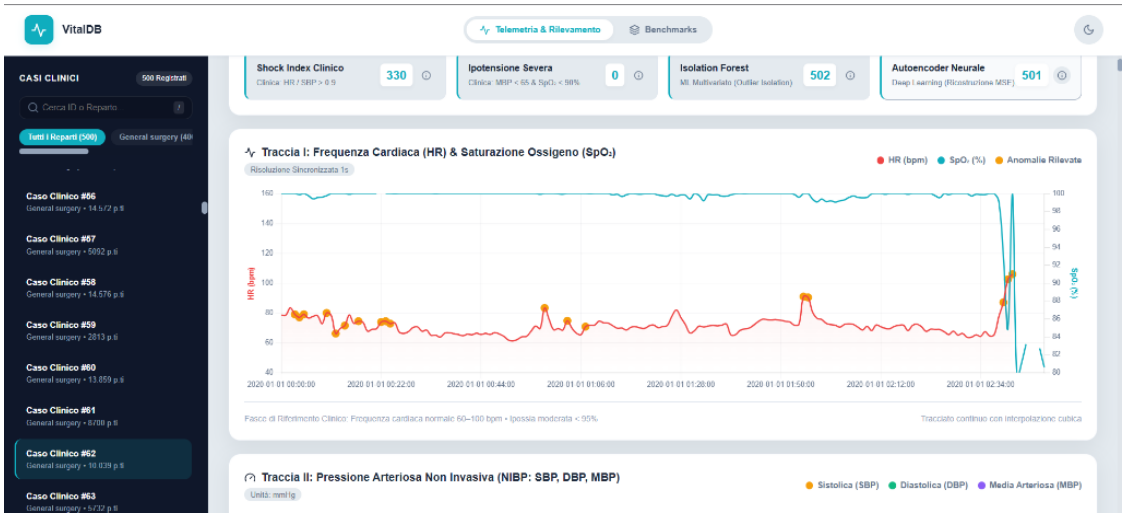


Figura 5.1: Quadro clinico del paziente e matrice di consenso a quattro metodi sulla dashboard web (caso #62).

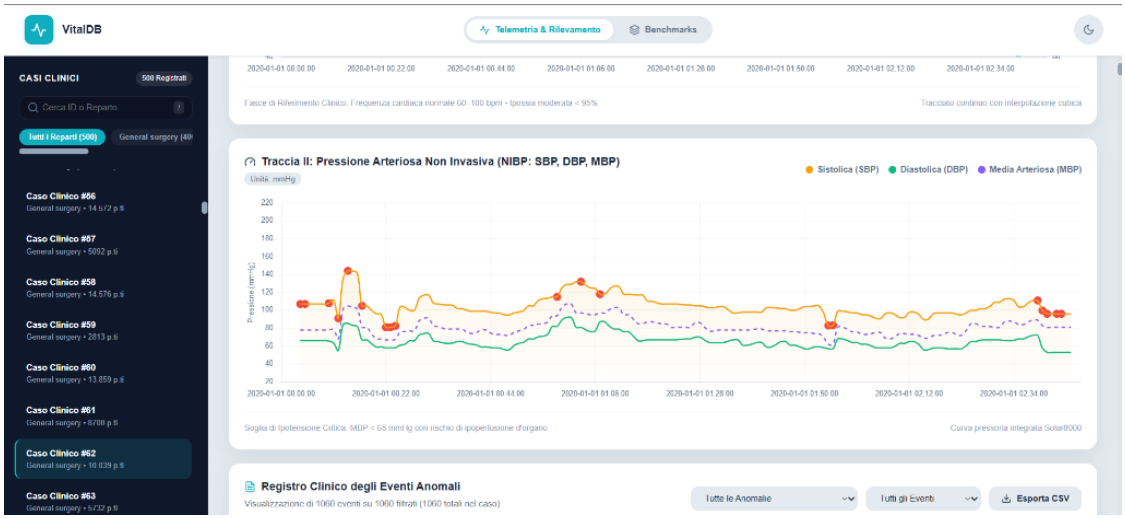
Subito sotto la matrice di consenso trovano posto i due grafici temporali sincronizzati illustrati nella Figura 5.2. Il primo grafico (Figura 5.2a) sovrappone l'andamento della frequenza cardiaca in rosso e della saturazione d'ossigeno in azzurro evidenziando gli istanti anomali con indicatori circolari dorati; il secondo grafico (Figura 5.2b) riporta l'evoluzione delle tre componenti pressorie (`SBP`, `DBP` e `MBP`) rispetto alla linea di riferimento clinico di 65 mmHg. La vista si chiude nella parte inferiore con il registro tabellare degli eventi anomali mostrato nella Figura 5.3, che elenca in ordine cronologico tutti gli istanti segnalati classificandoli per livello di severità in base al numero di algoritmi concordi (**advisory** con un solo metodo attivo, **warning** con due metodi concordi e **critical** con tre o quattro metodi) e permette di scaricare l'intero prospetto in formato CSV.

5.2.2 Vista di monitoraggio dell'architettura e dei benchmark

La seconda vista della dashboard, gestita dallo script `dashboard/js/lakehouse.js`, interroga gli endpoint `/benchmark`, `/evaluation` e `/quality` per esporre le metriche ingegneristiche dell'ultimo ciclo di esecuzione della pipeline. I pannelli superiori presentano il confronto sullo spazio occupato dai tre livelli (**33,95 MB** in bronze, **44,52 MB** in silver e **15,60 MB** di dati compressi in gold oltre a **2,56 MB** di indici B-Tree), dimensionando le barre grafiche rispetto al valore massimo tramite `Math.max(bronzeMB, silverMB, goldMB)`, insieme al confronto sui tempi di risposta (**12,02 ms** su MongoDB contro **26,95 ms** su Parquet). I pannelli inferiori espongono la tabella con le metriche di valutazione dei modelli non supervisionati sui $5.402.386$ campioni e il prospetto sulla



(a) Andamento di frequenza cardiaca e saturazione d'ossigeno con evidenziazione degli istanti anomali.



(b) Andamento della pressione arteriosa sistolica, diastolica e media rispetto alla soglia di rischio.

Figura 5.2: Grafici temporali sincronizzati sulla dashboard web per l'ispezione del tracciato a risoluzione di un secondo.

qualità della bonifica, che rendiconta le $5.565.384$ righe grezze iniziali, le 162.998 righe inattive rimosse $(2,93\%)$ e il dettaglio di outlier e valori mancanti per ciascun intervento.

5.3 Containerizzazione Docker, orchestrazione e test automatici

Per assicurare che l'intero ambiente sia riproducibile su qualsiasi sistema operativo senza richiedere l'installazione manuale di MongoDB 8.0 o di librerie scientifiche locali, la piattaforma è stata incapsulata in due container gestiti da `docker-compose.yml`, secondo lo schema architetturale rappresentato nella Figura 5.4.

Sulla rete virtuale isolata `vitaldb_net` operano il container `vitaldb_mongo`, basato sull'immagine ufficiale `mongo:8.0` avviata con l'opzione `-replSet rs0` e dotata di una sonda di controllo (`healthcheck`) che verifica o inizializza automaticamente il replica set tramite `mongosh`, e il container `vitaldb_api`, costruito a partire da `python:3.12-slim` con tutte le dipendenze di `requirements.txt` (inclusa la distribuzione CPU di PyTorch). Grazie alla direttiva `depends_on` vincolata alla condizione `service_healthy`, il servizio FastAPI attende che il motore MongoDB

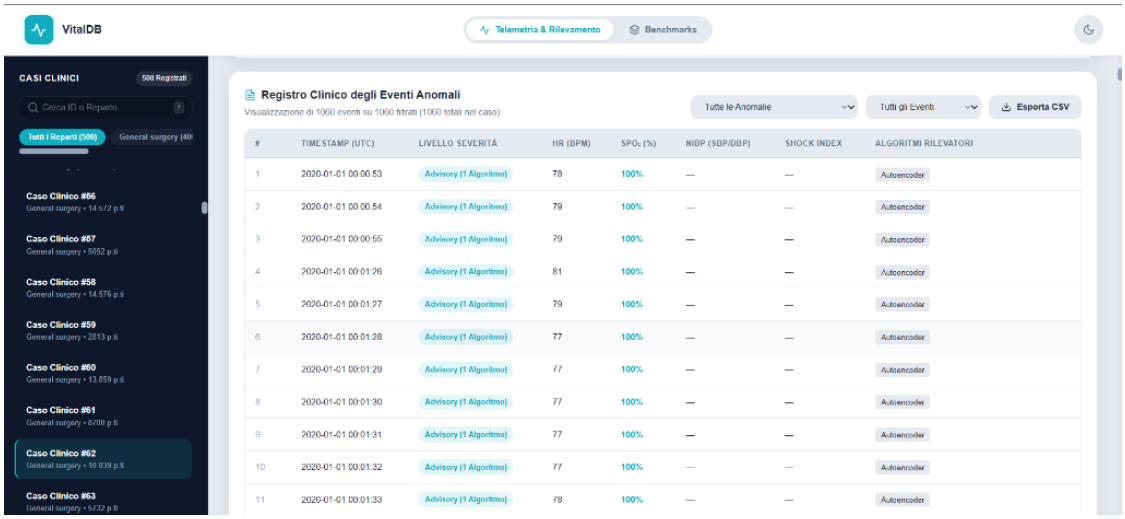


Figura 5.3: Registro cronologico degli eventi anomali con indicazione della severità, dei parametri vitali e funzione di esportazione CSV.



Figura 5.4: Architettura complessiva del sistema a tre tier, endpoint REST e distribuzione dei servizi nei container Docker.

abbia completato l'elezione del nodo primario prima di accettare richieste sulla porta `8000`.

L'esecuzione ordinata dei sei stadi della pipeline sui 500 casi clinici — scaricamento bronze (`download.py`), pulizia silver (`clean.py`), caricamento gold (`load_mongo.py`), rilevamento delle anomalie (`detector.py`), benchmark delle prestazioni (`benchmark_etl.py`) e valutazione dei modelli (`evaluate_models.py`) — è governata dallo script orchestratore `scripts/run_pipeline.py`, avviabile con un unico comando:

```
docker exec vitaldb_api python -u scripts/run_pipeline.py
```

L'orchestratore lancia i sei moduli in sequenza controllando il codice di uscita di ciascun sottoprocesso e interrompe immediatamente la catena qualora una fase restituisca un errore (`exit code != 0`), evitando disallineamenti tra i file su disco e le collezioni del database. A supporto dei cicli di sviluppo è stato inoltre realizzato lo script `scripts/reset_pipeline.py`, che previa conferma (`-yes`) svuota le collezioni MongoDB e rimuove i file Parquet e i report JSON per consentire una ripartenza da zero.

La correttezza funzionale dell'intero codice è presidiata da una suite di **38 test automatici** eseguibili tramite `pytest` e distribuiti in sei moduli nella cartella `tests/`, riepilogati nella Tabella 5.1. In particolare, nei test dell'endpoint `POST /cases/{id}/detect` dentro `tests/test_api.py` viene sostituito dinamicamente il metodo di scrittura `save_anomalies_to_mongo` tramite `monkeypatch`, così da verificare l'intera catena di calcolo senza sovrascrivere nel database le anomalie reali calcolate sulla coorte di 500 pazienti.

Modulo di test	Numero test	Ambito di verifica e garanzie controllate
`tests/test_config.py`	2	Coerenza degli intervalli fisiologici in `TRACK_SPECS` ($\min < \max$) e verifica che la soglia clinica `NIBP_MAX_CLINICAL_AGE_S` (120 s) non superi il limite LOCF (300 s).
`tests/test_bronze.py`	3	Scrittura atomica tramite file temporaneo (`.tmp` $\rightarrow$ `.parquet`), integrità delle colonne scaricate e generazione di `download_manifest.json` con `run_id`.
`tests/test_etl.py`	4	Interpolazione lineare limitata ai soli buchi interni ≤ 5 s, calcolo degli outlier prima dell'imputazione, tracciamento dei cinque flag `*_imputed` e verifica dell'identità `observed` $+$ `imputed` $+$ `missing` $=$ `rows_cleaned`.
`tests/test_gold.py`	16	Conversione in documenti BSON con omissione dei campi `NaN`, validazione `validate_records`, struttura del `registry`, filtro sui soli casi `committed` e recupero automatico `recover_incomplete_loads`.
`tests/test_detection.py`	9	Calcolo di shock index e ipotensione severa, blocco degli allarmi con `nibp_age_s` > 120 s, isolamento delle finestre scorrevoli tra pazienti diversi, presenza del proiettore `nn.Linear` e assenza di contaminazione tra casi nel `.bfill()` raggruppato.
`tests/test_api.py`	4	Collaudo tramite `TestClient` delle rotte `/health`, `/cases`, `/cases/{id}/series` e `POST /cases/{id}/detect` con isolamento del database tramite `monkeypatch`.

Tabella 5.1: Riepilogo dei 38 test unitari e di integrazione sviluppati con `pytest` nella cartella `tests/`.

5.4 Conclusioni, analisi dei limiti e sviluppi futuri

Il lavoro svolto ha permesso di progettare, implementare e validare su una coorte reale di **500 interventi chirurgici** estratti da VitalDB (**5.565.384 secondi grezzi** nel livello bronze e **5.402.386 secondi bonificati** nei livelli silver e gold) una piattaforma completa di ingegneria dei dati e rilevamento automatico delle anomalie. I risultati sperimentali confermano anzitutto il valore pratico della separazione dei ruoli nell'architettura medallion: conservare i tracciati originali in Apache Parquet nel livello bronze (**33,95 MB**) ha svincolato lo sviluppo dai tempi di rete dell'API remota; utilizzare il livello silver (**44,52 MB**, $+31,1\%$) per arricchire le tabelle con dodici colonne di qualità e ridurre i valori mancanti dal $66,3\%$ al $26,3\%$ senza cancellare gli outlier ha garantito una tracciabilità trasparente; infine, modellare il livello gold sulle collezioni temporali di MongoDB 8.0

ha compresso i dati fisici a **15,60 MB** ($-65,0\%$ rispetto a silver, oltre a **2,56 MB** di indici B-Tree) dimezzando i tempi di risposta sulle interrogazioni per singolo paziente (**12,02 ms** contro **26,95 ms**, pari a un fattore **2,2**$\times$). Altrettanto determinante si è rivelata la cura nella preparazione del dato per gli algoritmi a valle: rilevare gli outlier prima della propagazione in avanti, distinguere l'orizzonte di mantenimento pressorio nel livello silver (300 s) dal vincolo di freschezza per le regole cliniche (120 s) e confinare il `.bfill()` dentro ciascun `case_id` hanno evitato distorsioni sistematiche nei modelli.

Accanto ai risultati raggiunti, un'analisi critica dell'architettura realizzata consente di mettere in luce con trasparenza i limiti progettuali e operativi dei singoli componenti. Per quanto riguarda i livelli **bronze e silver**, il controllo sui file già presenti su disco prima di applicare lo stato `skipped_existing` verifica la presenza delle colonne e il passo di campionamento tra i primi due secondi senza ricalcolare un'impronta crittografica dell'intero file Parquet, mentre i referti salvati in `lab_data.parquet` vengono storicizzati ma non sono ancora integrati con le serie a 1 Hz. Nel livello silver, inoltre, la scelta di non rimuovere fisicamente i campioni marcati come `*_outlier` fa sì che la loro esclusione effettiva avvenga solo al momento della lettura in `load_from_gold`, e non è ancora previsto un filtro bloccante a livello di intero paziente (**quality gate**) che escluda dal caricamento nel livello gold gli interventi caratterizzati da una copertura sensoriale molto bassa.

Sul fronte del **livello gold e del data lakehouse applicativo**, le restrizioni native delle collezioni temporali di MongoDB 8.0 — che non supportano transazioni multi-documento verso il `registry` né validatori `$jsonSchema` su `vital_signals` — implicano che l'atomicità del caricamento a due fasi e il controllo dei tipi sulle misure dipendano dal passaggio attraverso gli script Python e dalla procedura di recupero `recover_incomplete_loads`, anziché essere imposti dal motore del database su qualsiasi scrittura esterna. Allo stesso modo, l'identificativo di esecuzione `run_id` è registrato nel catalogo `registry` e nei quattro file JSON senza essere replicato dentro ciascuno dei $5,4$ milioni di documenti temporali, l'asse del tempo parte dalla data convenzionale del 1° gennaio 2020 poiché VitalDB fornisce solo secondi relativi anonimizzati, e l'interrogazione `GET /cases` richiede ancora uno stadio di raggruppamento `$group` su `vital_signals` per recuperare reparto, età e sesso dei pazienti. Anche i risultati del benchmark di latenza vanno letti nel loro contesto specifico: il vantaggio di $2,2\times$ misura l'interrogazione selettiva di un singolo paziente con dati caldi in memoria su macchina singola, mentre su scansioni analitiche dell'intera coorte senza filtri la lettura colonnare diretta dei file Parquet rimane altamente competitiva.

Relativamente al modulo di **anomaly detection e ai servizi applicativi**, l'impostazione di `contamination=0.05` in isolation forest e del 95° percentile nell'autoencoder LSTM fissa per costruzione al 5% la frazione di campioni segnalati, configurando i due algoritmi come meccanismi di ordinamento per severità anziché come stimatori autonomi della prevalenza patologica, mentre la valutazione tramite PR-AUC ($0,105$ e $0,067$) misura la concordanza interna rispetto alle regole cliniche in assenza di diagnosi mediche indipendenti. Inoltre, il sistema attuale non salva su disco i pesi dei modelli addestrati sull'intera coorte (`.pkl` e `.pt`) e non espone una rotta `GET /cases/{id}/anomalies` di sola lettura: quando l'utente avvia il rilevamento dalla dashboard tramite `POST /cases/{id}/detect`, la pipeline riaddestra i modelli sul solo paziente selezionato e aggiorna per quel caso i record in `anomalies_detected`. Infine, sul piano dell'interfaccia web, la vista architetturale limita la tabella di dettaglio ai primi 15 pazienti per mantenere reattivo il browser e non espone ancora nell'intestazione grafica gli identificativi `run_id` e `pipeline_version`.

Questi stessi limiti tracciano in modo diretto le quattro direttrici di sviluppo futuro del progetto: la serializzazione su disco dello `StandardScaler`, del modello `IsolationForest` e dei pesi PyTorch dell'autoencoder addestrati sui 500 casi, separando nell'API la consultazione immediata degli allarmi precalcolati (`GET /cases/{id}/anomalies`) dal ricalcolo esplicito; l'inserimento nel documento del catalogo `registry` dei campi anagrafici (`department`, `age`, `sex`) per servire la rotta `GET /cases`

senza interrogare `vital_signals`, affiancato da un identificativo `detection_run_id` nei record di anomalia; l'introduzione nel livello silver di una soglia minima di copertura per paziente prima della promozione a gold; e infine il passaggio dallo script sequenziale `run_pipeline.py` a un orchestratore a grafo di dipendenze come Apache Airflow o Prefect, estendendo l'analisi anche alla pressione arteriosa invasiva (`ART`), alla capnografia ($EtCO_2$) e all'indice bispettrale (`BIS`).